

# ORB CORE

## FORENSIC MASTER REPORT

---

Konsolidierung aller ORB-Core-Forensikberichte vom 21. September 2026 – Ausgabe mit Kausalitätsnachweis

|                |                                                              |
|----------------|--------------------------------------------------------------|
| Datum          | 2026-09-21                                                   |
| Version        | 1.0                                                          |
| Umgebung       | Production                                                   |
| Modus          | READ-ONLY Quellenanalyse – keine Codeänderung                |
| Quellberichte  | 15                                                           |
| Klassifikation | KAUSAL BEWIESEN · DIREKT BEOBACHTET · WAHRSCHEINLICH · OFFEN |

# Inhaltsverzeichnis

## ORB CORE — FORENSIC MASTER REPORT

Evidenzklassifikation

Quellenberichte (15)

### 1. Executive Summary

### 2. Ausgangslage

### 3. Autonomous Question Path

### 4. Energy Forensics

4.1 Drei Energiebegriffe

4.2 Belegte Energie-Abflüsse

4.3 Live-Werte

4.4 Der Abfall 11-15 % → 1 %

4.5 Behebung (dokumentiert, außerhalb dieses Berichts erfolgt)

### 5. LISTEN / Autonomous Path

### 6. Observability

6.1 Forensischer Befund

6.2 Umgesetzte Änderung (dokumentiert, außerhalb dieses Berichts erfolgt)

6.3 Fortbestehende Grenzen

### 7. Memory Recall

7.1 Belegte Persistenz (Case 2, 19.09.2026)

7.2 Abgrenzungen

### 8. Die „Reisen“-Fehlverknüpfung

### 9. Selbstkorrektur

### 10. Die drei eigenen Fragen des 21.09.

### 11. „ORB denkt ...“ — Forensik

11.1 Lebenszyklus des Nachdenken-Zustands

11.2 Alle Fehlerpfade

11.3 Ergebnis

### 12. Cross-System Causality

### 13. Kausalitätstabelle

### 14. Technische Evidenz

### 15. Was heute NICHT bewiesen wurde

### 16. Abschlussbewertung

KAUSAL BESTÄTIGT

DIREKT BEOBACHTET

OFFEN

# ORB CORE — FORENSIC MASTER REPORT

Datum: 2026-09-21 · Version: 1.0 · Umgebung: Production · Modus: READ-ONLY Quellenanalyse

Zusammenführung aller am 2026-09-21 erstellten oder aktualisierten ORB-Core-Forensik-, Audit- und Untersuchungsberichte. Keine Codeänderung, keine Datenbankänderung, keine Migration, keine Konfigurationsänderung, keine Teständerung, kein Deployment im Rahmen dieses Berichts.

## Evidenzklassifikation

| Status            | Bedeutung                                                                                                    |
|-------------------|--------------------------------------------------------------------------------------------------------------|
| KAUSAL BEWIESEN   | Ursache → Wirkung technisch nachvollzogen und durch Code, DB-Zeilen, Trigger, Test oder Laufzeitdaten belegt |
| DIREKT BEOBACHTET | Ereignis sicher belegt, vollständige Ursache nicht bewiesen                                                  |
| WAHRSCHEINLICH    | technisch plausibel, kein vollständiger Kausalitätsnachweis                                                  |
| OFFEN             | keine ausreichende Evidenz                                                                                   |

## Quellenberichte (15)

| #  | Bericht                                                      | Gegenstand                                                  |
|----|--------------------------------------------------------------|-------------------------------------------------------------|
| 1  | ORB_ENERGY_RECOVERY_DESIGN_SIMULATION_2026-09-21.md          | Entwurf und Simulation der Energie-Erholung                 |
| 2  | ORB_ENERGY_RECOVERY_IMPLEMENTATION_PRODUCTION_2026-09-21.md  | freigegebene Umsetzung +0.02/min, Cap 0.25                  |
| 3  | ORB_PROACTIVE_QUESTIONING_BLOCK_ANALYSIS_2026-09-21.md       | Blockade eigener Fragen, Energie als Sperre                 |
| 4  | ORB_PROACTIVE_COUNTERFACTUAL_SIMULATION_2026-09-21.md        | Gegenprobe der Gates                                        |
| 5  | ORB_LISTEN_AUTONOMY_FORENSIC_2026-09-21.md                   | LISTEN als Prompt-Wortlaut, nicht als Sperre                |
| 6  | ORB_ENERGY_FORENSIC_LIVE_EVENT_2026-09-21.md                 | Live-Abfall 11-15 % → 1 %                                   |
| 7  | ORB_AUTONOMY_OBSERVABILITY_FORENSIC_2026-09-21.md            | 25 Gates, stille Ablehnungen                                |
| 8  | ORB_AUTONOMY_OBSERVABILITY_IMPLEMENTATION_2026-09-21.md      | Testbereich-Anzeige des letzten Versuchs                    |
| 9  | ORB_AUTONOMY_OBSERVABILITY_UI_VISIBILITY_CHECK_2026-09-21.md | Auffindbarkeit der Anzeige                                  |
| 10 | ORB_FORENSIC_CASE2_PERSONAL_MEMORY_2026-09-21.md             | Persistenz und Abruf persönlicher Angaben (19.09.)          |
| 11 | ORB_CROSS_CASE_AUTONOMY_ARCHITECTURE_2026-09-21.md           | Vergleich Curiosity- und Impuls-Zweig                       |
| 12 | ORB_FORENSIC_MEMORY_RECALL_AUTONOMY_2026-09-21.md            | drei eigene Fragen, Reisen-Fehlverknüpfung, Selbstkorrektur |
| 13 | ORB_ENERGY_MESSAGE_RESET_FIX_2026-09-21.md                   | Ursache und minimale Behebung des Energie-Rücksetzers       |
| 14 | ORB_CORE_OBJECTIVE_MATURITY_ASSESSMENT_2026-09-21.md         | Reifegrad-Bestandsaufnahme                                  |
| 15 | ORB_THINKING_STUCK_FORENSIC_2026-09-21.md                    | „ORB denkt ...“ ohne sichtbare Folge                        |

# 1. Executive Summary

Fünf Ursache-Wirkungs-Ketten wurden heute vollständig belegt.

**1. Energie-Erholung wurde durch fremde Zustandsschreibvorgänge neutralisiert (KAUSAL BEWIESEN).** Der angezeigte Energiewert wird zur Laufzeit als gespeicherter Wert +  $\Delta t \cdot 0.02$  berechnet, wobei  $\Delta t$  aus `orb_state.updated_at` stammt. Zwei nicht energiebezogene Schreibvorgänge — `decay_computations` in `getSnapshot()` und der Lernzähler in `recordLearning()` — schrieben `orb_state` ohne `energy`. Der Trigger `orb_state_updated_at` setzte dabei `updated_at = now()`. Damit war  $\Delta t$  wieder nahe 0, die aufgelaufene Erholung verfiel, und die anschließenden Nachrichtenkosten wurden auf einen nicht erhaltenen Wert angewandt; `clamp01()` ergab exakt 0.

**2. Die Blockade eigener Fragen war ein Energie-Gate, nicht LISTEN (KAUSAL BEWIESEN).** `decideCuriosity()` liefert `WAIT`, sobald `energy < 0.15`. Der Modus `LISTEN` existiert nur als Antwort-Etikett und als ein Satz Prompt-Wortlaut; im eigenständigen Fragenweg wird er nicht gelesen und nicht einmal in den Prompt übergeben.

**3. Die Energie-Erholung arbeitet zur Laufzeit korrekt (KAUSAL BEWIESEN, live reproduziert).** Live-Werte aus `orb_messages.state_snapshot`: 0.00696 → 0.19096 → 0.18070 → 0.21162; nach der Behebung von Punkt 1 wurde um 11:34:38 UTC der gespeicherte Wert 0.25 erreicht — die Obergrenze.

**4. Die „Reisen“-Fehlverknüpfung entstand beim Memory-Ingest am 19.09. (KAUSAL BEWIESEN).** `topicOf()` vergleicht Wortstämme in beide Richtungen. Der Stamm `wand` aus „wandern“ trifft das Reise-Schlüsselwort `wander`. Der Knoten wurde deshalb am 19.09. mit dem Thema `reisen` gespeichert. Das Sprachmodell erhielt am 21.09. eine bereits falsch klassifizierte Erinnerung.

**5. Long-Term-Memory-Retrieval ist belegt (KAUSAL BEWIESEN).** Ein am 19.09. persistierter Knoten wurde am 21.09. über Ähnlichkeit, Relevanz und Rangfolge geladen und mit berechneter Sicherheitsstufe „wahrscheinlich“ (Schwelle 0.3 / 0.6) in die Antwort übernommen.

Direkt beobachtet, aber ursächlich nicht abgeschlossen: das Muster „ORB denkt ... danach nichts“. Belegt ist, dass der Nachdenken-Hinweis technisch nicht hängen bleiben kann und dass eine Ablehnung bewusst ohne sichtbaren Abschluss endet. Welches Gate im konkreten Ereignis um 11:30 UTC ablehnte, ist OFFEN, weil Ablehnungen nicht persistiert werden.

Nicht als Mechanismus bestätigt: die beobachtete Selbstkorrektur. Es existiert kein Prüfschritt, der Themenplausibilität oder die Voraussetzung einer früheren eigenen Frage gegen den Abruf hält.

---

## 2. Ausgangslage

Stand zu Tagesbeginn (2026-09-21, 06:30 UTC):

- Die Energie-Erholung (+0.02/Minute, Obergrenze 0.25, Kosten einer eigenen Frage 0.03) war am Vortag freigegeben und in Production veröffentlicht. Der gespeicherte Energiewert lag bei 0.
  - Es existierten 0 eigene Fragen des laufenden Tages; der letzte proactive-Metrikeintrag stammte vom 2026-09-20 07:26:13.
  - Das Verhalten „ORB stellt keine eigenen Fragen mehr“ war offen und wurde von ORB selbst mit „LISTEN-Vorgaben“ begründet.
  - Der Energiewert der Anzeige schwankte sichtbar ohne erkennbare Nutzeraktion.
-

### 3. Autonomous Question Path

Nur tatsächlich im Code belegte Komponenten. Dateien und Zeilen in Kapitel 14.

```
Browser: Leerlauf-Beobachter (use-orb-presence.ts, Intervall 5 s, rein rechnerisch)
G1 Tab sichtbar
G2 kein Tippen
G3 Mikrofon inaktiv
G4 ORB spricht nicht
G5 keine laufende Anfrage (pending)
G6 Leerlauf >= 40 s
G7 Leerlauf <= 15 min
G8 Neugier-Band != low
G9 Client-Cooldown (low/medium 300 s, high 180 s, very_high 120 s)
  -> Sofortssperre lastProactiveRef = now (verhindert Doppelaufruf)
  -> genau EIN Serveraufruf: requestOrbCuriosity
Server: askProactively(db, userId)
  loadCuriosityContext: 12 Knoten, 8 Interessen, 8 Nachrichten, Fragenhistorie, 60 Verbindungen
  CURIOSITY-Zweig decideCuriosity()
    G10 mindestens eine Wissenslücke
    G11 Neugier ausreichend (mayAskAtCuriosity)
    G12 energy >= 0.15 -> sonst WAIT
    G13 keine offene eigene Frage -> sonst WAIT
    G14 Server-Cooldown -> sonst WAIT
    G15 Kandidatenwert >= 0.20 -> sonst WAIT
  IMPULSE-Zweig decideImpulse()
    Suppression, offene Frage, Duplikat/bekannt, Priorität, Wert >= 0.20
  Merge: impulse ? gapFromImpulse(...) : decision.gap
  Formulation: formulateQuestion() -> Sprachschicht (Zeitlimit per AbortSignal)
    -> Statusfehler = still
  Duplikatprüfung: isDuplicateQuestion (Ähnlichkeitsschwelle 0.6) -> still
  Persistenz (vier Schreibvorgänge, nicht transaktional):
    orb_questions -> orb_messages (state_snapshot.proactive = true, question_id)
    -> orb_state (curiosity -0.06, energy -0.03) -> orb_metrics kind = 'proactive'
  Rückgabe: asked = true, Frage, Snapshot
  UI: curiosityMutation.onSuccess
    Versuch wird immer in die Testbereich-Anzeige geschrieben
    bei asked = false: bewusster Abbruch, keine Chat-Ausgabe
    bei asked = true: Snapshot, Chat-Zeile, optional Sprachausgabe, Cooldown
```

Belegte Eigenschaften dieses Pfades:

- Die Entscheidung \*ob\* und \*worüber\* gefragt wird, ist deterministisch; nur die Formulierung stammt aus der Sprachschicht. **KAUSAL BEWIESEN**
- Der Takt liegt ausschließlich im Browser; ohne geöffnete ORB-Ansicht existiert kein eigenständiger Fragenweg. **KAUSAL BEWIESEN**
- Die vier Persistenzschritte sind nicht in einer Transaktion gebündelt; ein Fehler nach dem ersten Schritt kann eine Fragenzeile ohne Nachricht hinterlassen. **WAHRSCHEINLICH** (Codelage belegt, kein Vorfall beobachtet)

## 4. Energy Forensics

### 4.1 Drei Energiebegriffe

| Begriff    | Definition                                                                                                              | Ort                    |
|------------|-------------------------------------------------------------------------------------------------------------------------|------------------------|
| STORED     | Spaltenwert orb_state.energy                                                                                            | Datenbank              |
| CALCULATED | $\text{recoverEnergy}(\text{stored}, \text{updated\_at}, \text{now}) = \min(0.25, \text{stored} + \Delta t \cdot 0.02)$ | toState() zur Laufzeit |
| DISPLAYED  | CALCULATED, gerundet in Prozent; steuert zusätzlich die Avatar-Darstellung ab 0.20                                      | Oberfläche             |

**KAUSAL BEWIESEN:** Der angezeigte Wert war nie der gespeicherte Wert. Der Zeitanker der Erholung ist kein eigenes Feld, sondern orb\_state.updated\_at.

### 4.2 Belegte Energie-Abflüsse

| Quelle                                              | Betrag           | Beleg                                  |
|-----------------------------------------------------|------------------|----------------------------------------|
| normale Nachricht (Zustandsverfall in processInput) | zustandsabhängig | state_snapshot.energy je Turn          |
| gestellte eigene Frage                              | −0.03            | askProactively, Zustandsupdate         |
| sonstige Verbraucher                                | keine gefunden   | Suche über alle orb_state-Schreibpfade |

Abgelehnte Versuche, Rendern, der Nachdenken-Hinweis, Abfragen und LISTEN verbrauchen **keine** Energie. **KAUSAL BEWIESEN**

### 4.3 Live-Werte

Quelle: orb\_messages.state\_snapshot.energy (Production, Nutzer 9ce1d1b0-...).

| Zeit (UTC)  | Wert          | Bedeutung                                                                |
|-------------|---------------|--------------------------------------------------------------------------|
| 08:36:16    | 0.00696       | Ausgangswert nach dem Rücksetz-Effekt, kurz vor der ersten eigenen Frage |
| 08:45:30    | 0.19096       | Snapshot der eigenen Frage A — Erholung erstmals zur Laufzeit belegt     |
| 08:54:27    | 0.18070       | Snapshot der eigenen Frage B, nach Kosten 0.03 und erneuter Erholung     |
| 08:59:57    | 0.21162       | Snapshot der eigenen Frage C                                             |
| 11:19-11:22 | 0.206 → 0.103 | Absinken durch mehrere aufeinanderfolgende Nachrichten                   |
| 11:30:17    | 0.208         | Erholung nach Gesprächspause                                             |
| 11:34:38    | 0.25 (STORED) | Obergrenze erreicht; erstmals ist auch der gespeicherte Wert erholt      |

Die Reihe 0.007 → 0.191 → 0.181 → 0.212 ist damit nicht eine Messung derselben Größe in gleichen Abständen, sondern die Energie **zum Zeitpunkt von vier verschiedenen Ereignissen**: einem normalen Turn und den drei eigenen Fragen.

### 4.4 Der Abfall 11-15 % → 1 %

**KAUSAL BEWIESEN:** Anzeige-/Persistenz-Fehlpassung. Ausgeschlossen wurden wiederholte legitime Kosten (heute 2 Nachrichten, 0 Fragen), ein unbekannter Verbraucher (keiner existiert) und mehrfache autonome Zyklen (0 proactive-Metriken zum Zeitpunkt der Analyse). Ursache ist, dass getSnapshot() bei jedem Abruf decay\_computations schrieb; der Trigger setzte updated\_at = now(), Δt fiel auf 0, und die Anzeige sprang auf ≈ 0–1 % zurück. decay\_computations stand bei 4539 — jeder dieser Schreibvorgänge hatte denselben Effekt.

### 4.5 Behebung (dokumentiert, außerhalb dieses Berichts erfolgt)

Beide Schreibvorgänge schreiben seither zusätzlich energy: toState(stateRow).energy, also den zum Lesezeitpunkt erhaltenen Wert; der neue Zeitstempel gehört damit zum neuen Basiswert. Unverändert: Kosten, Rate +0.02/min, Obergrenze 0.25, Schwelle 0.15, alle Gates, Schema und RLS. Belegt durch 6 neue Tests sowie 1095 Logik- und 77 DB/Security-Tests.

## 5. LISTEN / Autonomous Path

### KAUSAL BEWIESEN:

- LISTEN existiert an genau drei Stellen: als Wert von ConversationMode, als Rückfallzweig von decideConversationMode() und als Eintrag in MODE\_HINT („stelle keine Frage“).
- Es gibt keine LISTEN-Spalte in orb\_state und keinen LISTEN-Zustand, der aktiv sein könnte.
- decideConversationMode() wird ausschließlich im Antwortweg (processInput) aufgerufen.
- askProactively() liest ConversationMode nicht; formulateQuestion() baut einen eigenen Prompt **ohne** Modusfeld. MODE\_HINT.LISTEN erreicht den eigenständigen Fragenweg nicht.
- Der einzige ausführbare Effekt von LISTEN ist, dass für die Antwort Gesprächsfäden und Fokusthema geleert werden.

**Entstehung der früheren Fehlinterpretation (KAUSAL BEWIESEN):** ORB selbst hatte formuliert, „LISTEN-Vorgaben verbieten mir, eine Frage zu stellen“. Diese Aussage ist Modelltext. Technisch entschied die Energie: beide betroffenen Antworten tragen decision = stay\_silent, und decide() liefert stay\_silent, sobald energy < 0.12. FOLLOW\_UP und SMALLTALK verlangen ebenfalls energy >= 0.12. LISTEN war die Folge niedriger Energie, nicht deren Ursache.

---

## 6. Observability

### 6.1 Forensischer Befund

**KAUSAL BEWIESEN:** Der eigenständige Fragenweg hatte 25 Entscheidungspunkte, von denen 24 vollständig still waren. Clientseitig (G1–G9) verlässt die Begründung den Browser nie; sie lag nur in React-State. Serverseitig gibt `silent(reason)` ein einfaches Objekt zurück — keine Protokollzeile, keine Metrik, keine Fragen-, Nachrichten- oder Zustandszeile. Nur der tatsächlich gesendete Fall hinterlässt eine dauerhafte Spur (`orb_questions + orb_messages.state_snapshot.proactive + orb_metrics` `kind = 'proactive' + Energie –0.03`). Ein geworfener Datenbankfehler war ausschließlich in der Browserkonsole sichtbar.

Nicht rekonstruierbar waren damit: ob der Beobachter überhaupt auslöste, welches der 16 serverseitigen Gates ablehnte, der Energiewert im Entscheidungsmoment, der Kandidatenwert einer Ablehnung, die Anzahl der Versuche einer Sitzung und ob die Sprachschicht ausfiel.

### 6.2 Umgesetzte Änderung (dokumentiert, außerhalb dieses Berichts erfolgt)

Reine Client-Anzeige: der vom Server ohnehin zurückgegebene Grund des letzten Versuchs wird im bestehenden Testbereich als „Letzter eigener Fragen-Versuch“ dargestellt (Zeitpunkt, asked, Aktion, Grund, Thema, Lückenart, Wert). Keine Änderung an Entscheidung, Schwellen, Energie, Persistenz, Datenbank, Anfragen, Zeitgebern oder Server.

### 6.3 Fortbestehende Grenzen

- Die Anzeige ist sitzungslokal und nach einem Neuladen verloren. **KAUSAL BEWIESEN**
- Ein ausgebliebener Versuch bleibt unklassifiziert (nicht ausgelöst oder clientseitig abgelehnt).

#### **KAUSAL BEWIESEN**

- Der Abschnitt liegt hinter zwei standardmäßig geschlossenen Ebenen (Technische Informationen → Status) und unterhalb des sichtbaren Bereichs; es existiert kein Entwickler-, Admin-, Umgebungs- oder Feature-Schalter davor. **KAUSAL BEWIESEN**

- Fehler des eigenständigen Weges gehen weiterhin nur in die Browserkonsole. **KAUSAL BEWIESEN**
-

## 7. Memory Recall

### 7.1 Belegte Persistenz (Case 2, 19.09.2026)

| Zeit (UTC)   | Ereignis                                                                                                                    | Beleg                        |
|--------------|-----------------------------------------------------------------------------------------------------------------------------|------------------------------|
| 18:04:31.688 | Nutzeraussage mit Lieblingsessen, Getränk, Schuhgröße 42, Grafikkarte RTX 5070                                              | orb_messages b610a162-...    |
| 18:04:31.689 | Modellantwort „... merke ich mir ...“, recalled = 0                                                                         | orb_messages ff3cb09b-...    |
| 18:04:35.100 | Persistenz eines Knotens mit dem <b>Rohsatz</b> , importance 0.48 $\geq$ Schwelle 0.35, confidence 0.9, user_stated, active | orb_nodes 132bf051-...       |
| 18:05:12.998 | eigener Beitrag ohne neue Nutzereingabe, decision = ask, Curiosity-Zweig, gap_kind detail, score 0.40446                    | orb_questions 145b70ef-...   |
| 18:05:47.846 | Abruf: Fakten korrekt genannt, recalled = 1, nodes_loaded = 3                                                               | orb_messages 3fdce42f-...    |
| 18:05:51.729 | Zustandsänderung: erste Verbindung 132bf051 → 4e4167ac                                                                      | orb_connections 283725f0-... |

**KAUSAL BEWIESEN:** Eingabe → Erkennung → Entscheidung → Persistenz → Zustandsänderung → Abruf → Folgeverhalten. Die Modellaussage „merke ich mir“ entstand **vor** der Persistenz und ist kein Persistenznachweis. Es wurden keine vier Einzelfakten gespeichert, sondern eine Äußerung.

### 7.2 Abgrenzungen

- **Gesprächskontext:** Der Antwortweg lädt bis zu acht der letzten Nachrichten. Für die Antwort um 18:04:31 ist recalled = 0 belegt — sie stammte ausschließlich aus dem Kontextfenster. **KAUSAL BEWIESEN**

- Für 18:05:47 ist Abruf belegt (recalled = 1), der Rohsatz lag aber ebenfalls noch im Kontextfenster; die **Exklusivität** des Abrufs als Quelle ist an dieser Stelle nicht bewiesen.

#### WAHRSCHEINLICH

- **Graph:** Verbindungen beeinflussen Relevanz und den Impuls-Zweig. Der Curiosity-Lückenweg nutzt sie nicht direkt; Gesprächsfäden werden vom eigenständigen Fragenweg nicht geladen. **KAUSAL BEWIESEN**

- **Long-Term-Memory-Retrieval am 21.09.:** Der am 19.09. um 19:24:02 angelegte Knoten 1dfb5e07-... (importance 0.72, activation\_count 16) wurde am 21.09. über Ähnlichkeit, Relevanz und Rangfolge geladen. Die Formulierung „wahrscheinlich“ entstammt der berechneten Sicherheitsstufe (certainty0f: „sicher“ ab 0.6, „wahrscheinlich“ ab 0.3). Das Anzeigeetikett „ERINNERN“ ist die Darstellung der Entscheidung remind. **KAUSAL BEWIESEN**

## 8. Die „Reisen“-Fehlverknüpfung

Entstehungszeitpunkt: **2026-09-19, 19:24:02 UTC** · Entdeckungszeitpunkt: **2026-09-21**

Kausalkette, vollständig reproduziert:

Nutzertext: „... keine Zeit in den Graphen zu wandern“  
-> Tokenisierung/Stammbildung ergibt u. a. den Stamm wand  
-> topicOf() vergleicht bidirektional: t.startsWith(k) || k.startsWith(t)  
-> Themenschlüsselwort des Themas „reisen“ enthält wander  
-> "wander".startsWith("wand") ist wahr  
-> Thema des Knotens wird reisen  
-> Persistenz am 19.09. 19:24:02 als orb\_nodes 1dfb5e07-... (topic = reisen)  
-> 21.09.: Rangfolge wählt diesen Knoten als Wissenslücke  
-> eigene Frage A (08:45:30) und B (08:54:27) mit Thema reisen  
-> Nutzerantwort über Griechenland (08:51:42) verstärkt die Themenspur

**Status: KAUSAL BEWIESEN.** Ausdrücklich festgehalten:

- Die Fehlklassifikation entstand beim Memory-Ingest, nicht bei der späteren Textausgabe.
  - Sie entstand am 19.09., nicht am 21.09.
  - Das Sprachmodell erhielt eine bereits falsch klassifizierte Erinnerung; es hat nicht zwei Erinnerungen vermischt und keine Reiseinformation erfunden.
  - Der betroffene Knoteninhalt lautet wörtlich: „Okay ich sehe das problem. Der Chatverlauf ist zu kurz. Und die wichtigen Informationen haben keine Zeit in den Graphen zu wandern“.
  - Ein Konfidenzwert für die Themenzuordnung existiert nicht; ein falsches Thema ist daher von einem richtigen nicht unterscheidbar.
-

## 9. Selbstkorrektur

Beobachtet: ORB stellte später fest, dass ein konkreter Bezug zu Reisen in den betreffenden Erinnerungen nicht enthalten ist.

### **Belegt (KAUSAL BEWIESEN):**

- Es existiert kein Codeabschnitt, der die Plausibilität eines Themas prüft.
- Es existiert kein Codeabschnitt, der die Voraussetzung einer früheren eigenen Frage gegen den Abruf hält, und keine Nachverarbeitung der Antwort.
- Der Antwort-Prompt erhält den Erinnerungstext, **ohne** das Thema zu behaupten; der Frage-Prompt erhält das Themen-Etikett. Diese Asymmetrie ermöglichte die Korrektur.

**Klassifikation:** LLM-basierte Selbstkorrektur, ermöglicht durch asymmetrische Prompt-Zusammensetzung. Kein nachgewiesener eigener Validierungsmechanismus und keine Quellenzuordnung. Eine Wiederholbarkeit ist nicht garantiert. **DIREKT BEOBACHTET** für das Ereignis, **KAUSAL BEWIESEN** für die Abwesenheit eines Mechanismus.

---

## 10. Die drei eigenen Fragen des 21.09.

|                             | Frage A                                         | Frage B      | Frage C      |
|-----------------------------|-------------------------------------------------|--------------|--------------|
| Fragenzeile (orb_questions) | 08:45:30.976                                    | 08:54:27.211 | 08:59:57.407 |
| Nachricht / Metrik          | 08:45:33                                        | 08:54:30     | 09:00:01     |
| Thema                       | reisen                                          | reisen       | hardware     |
| Lückenart                   | detail                                          | kontext      | erfahrung    |
| Wert                        | 0.6425                                          | 0.6806       | 0.5995       |
| Quellknoten                 | 1dfb5e07-...                                    | 1dfb5e07-... | 59d932de-... |
| Energie im Snapshot         | 0.19096                                         | 0.18070      | 0.21162      |
| Neugier-Band                | very_high                                       | very_high    | very_high    |
| Weg                         | CURIOSITY                                       | CURIOSITY    | CURIOSITY    |
| state_snapshot.proactive    | true                                            | true         | true         |
| impulse im Snapshot         | null                                            | null         | null         |
| Persistenz                  | vollständig (Frage, Nachricht, Zustand, Metrik) | vollständig  | vollständig  |
| Ergebnis                    | beantwortet                                     | beantwortet  | beantwortet  |

**KAUSAL BEWIESEN:** Alle drei liefen über den CURIOSITY-Zweig, keine über IMPULSE (Nachweis: `impulse = null` im Snapshot jeder Zeile). Zwei aufeinanderfolgende Fragen stammen aus **einem** Knoten, weil die Lückenart wechselte (`detail` → `kontext`) und der Lückenschlüssel Knoten und Lückenart kombiniert. Ein früher im Testbereich beobachteter abgelehnter Versuch trug denselben Wert 0.643 wie die später gestellte Frage A — es fehlte ausschließlich die Energie.

Ergänzend belegt für den 21.09. nach 09:00: weitere eigene Fragen um 09:31:19, 09:36:43, 09:47:46, 10:47:22 und 10:49:57, alle beantwortet; danach keine weitere bis 11:36.

## 11. „ORB denkt ...“ — Forensik

### 11.1 Lebenszyklus des Nachdenken-Zustands

**KAUSAL BEWIESEN:** Es gibt keinen eigenen Zustandsschalter. Der Hinweis wird aus `sendMutation.isPending || curiosityMutation.isPending` abgeleitet und an drei Stellen angezeigt (Chatverlauf, Statuszeile, Gesicht). Folgen:

1. Start: automatisch mit dem Auslösen der Anfrage — also **vor** dem Serveraufruf.
2. Ende: automatisch beim Abschluss der Anfrage, bei Erfolg **und** bei Fehler.
3. Es existiert kein Rücksprung, der einen Schalter offen lassen könnte; ein `finally` ist nicht erforderlich.

### 11.2 Alle Fehlerpfade

| Fall                                             | Verhalten                                                      | Nachdenken endet | Sichtbarer Abschluss |
|--------------------------------------------------|----------------------------------------------------------------|------------------|----------------------|
| Gate lehnt ab ( <code>silent</code> )            | HTTP 200, <code>asked = false</code> , Grund im Ergebnis       | ja               | nein (bewusst)       |
| Persistenzfehler (geworfene Ausnahme)            | Fehlerzweig, nur Browserkonsole                                | ja               | nein                 |
| Netzwerkfehler / HTTP $\neq$ 200 / defektes JSON | Fehlerzweig, kein Wiederholungsversuch                         | ja               | nein                 |
| Sprachschicht hängt                              | ausgeschlossen: Zeitlimit per <code>AbortSignal.timeout</code> | ja               | nein                 |
| Komponente wird verlassen                        | Ergebnis verworfen, Zustand existiert nicht mehr               | entfällt         | entfällt             |
| Zwei gleichzeitige Versuche                      | verhindert durch <code>pending</code> -Gate und Sofortsperr    | ja               | entfällt             |

### 11.3 Ergebnis

**KAUSAL BEWIESEN:** Der Nachdenken-Hinweis erscheint auch für einen eigenständigen Versuch und zwar vor der Serverantwort; bei `asked = false` bricht die Oberfläche bewusst ohne Chat-Ausgabe, Meldung oder Hinweis ab. Das erzeugt genau das beobachtete Muster, obwohl der Ablauf korrekt und vollständig beendet ist.

**OFFEN:** Welches Gate im Ereignis um 11:30 UTC ablehnte. Zum Zeitpunkt der Analyse waren Energie 0.25, keine offene Frage und der Server-Cooldown erfüllt; die sitzungslokale Versuchsanzeige war nicht mehr vorhanden. Ein hängender Nachdenken-Zustand wurde **nicht** nachgewiesen; es wurde deshalb nichts geändert.

## 12. Cross-System Causality

### KETTE 1 – Energie-Zeitanker

Snapshot-Abruf / Lernzähler schreibt orb\_state ohne energy  
-> Trigger orb\_state\_updated\_at setzt updated\_at = now()  
->  $\Delta t = 0 \Rightarrow$  CALCULATED = STORED (niedrig)  
-> Nachrichtenkosten auf nicht erhaltenen Wert -> clamp01 = 0  
-> DISPLAYED springt auf 0 [KAUSAL BEWIESEN]

### KETTE 2 – Autonomie-Sperre

energy < 0.15 -> decideCuriosity = WAIT -> asked = false  
-> keine Frage, keine Spur, kein sichtbarer Abschluss [KAUSAL BEWIESEN]

### KETTE 3 – Erholung ermöglicht eigene Frage

Ruhezeit -> +0.02/min (Cap 0.25) -> Schwelle 0.15 erreicht  
-> Kandidatenwert 0.643 >= 0.20 -> Frage A 08:45:30 [KAUSAL BEWIESEN]

### KETTE 4 – Themenklassifikation

"wandern" -> Stamm "wand" -> bidirektionaler Vergleich mit "wander"  
-> Thema reisen -> Persistenz 19.09. -> Retrieval 21.09.  
-> eigene Fragen A und B mit Thema reisen [KAUSAL BEWIESEN]

### KETTE 5 – Long-Term-Memory

persistierter Knoten -> Ähnlichkeit/Relevanz/Rangfolge  
-> Antwortkontext -> Sicherheitsstufe "wahrscheinlich" [KAUSAL BEWIESEN]

### KETTE 6 – LISTEN

energy < 0.12 -> decide() = stay\_silent -> Modus LISTEN  
-> Prompt-Wortlaut "stelle keine Frage"  
-> Modellaussage "LISTEN verbietet mir zu fragen" [KAUSAL BEWIESEN]  
(LISTEN -> Blockade des eigenständigen Weges) [WIDERLEGT]

## 13. Kausalitätstabelle

| Befund                                                   | Ursache                                                                           | Wirkung                                                        | Evidenz                                                                                             | Status                                                            |
|----------------------------------------------------------|-----------------------------------------------------------------------------------|----------------------------------------------------------------|-----------------------------------------------------------------------------------------------------|-------------------------------------------------------------------|
| Energie erscheint nach einer Nachricht als 0             | orb_state-Schreibvorgänge ohne energy + Trigger auf updated_at                    | $\Delta t = 0$ , Erholung verfällt, clamp01 ergibt 0           | engine.server.ts (Snapshot- und Lernpfad), toState, Trigger orb_state_updated_at, DB-Zeile energy 0 | KAUSAL BEWIESEN                                                   |
| Anzeige fiel von 11-15 % auf $\approx 1$ %               | derselbe Zeitanker-Verlust bei jedem Snapshot-Abwurf                              | Anzeigesprung ohne Nutzeraktion                                | decay_computations = 4539, keine Kosten- oder Verbraucherzeile                                      | KAUSAL BEWIESEN                                                   |
| keine eigenen Fragen am Morgen                           | energy < 0.15                                                                     | decideCuriosity = WAIT                                         | curiosity.ts Gate, decision = stay_silent, 0 proactive-Metriken                                     | KAUSAL BEWIESEN                                                   |
| ORB nannte LISTEN als Verbot                             | Energie < 0.12 → stay_silent → Modus LISTEN → Prompt-Wortlaut                     | Modelltext mit falscher technischer Begründung                 | conversation.ts, core.ts decide(), prompt.server.ts                                                 | KAUSAL BEWIESEN                                                   |
| LISTEN blockiert eigene Fragen                           | -                                                                                 | -                                                              | askProactively liest den Modus nicht; formulateQuestion übergibt kein Modusfeld                     | WIDERLEGT                                                         |
| Energie-Erholung funktioniert                            | reine Zeitfunktion recoverEnergy                                                  | 0.007 → 0.191 → 0.181 → 0.212; STORED 0.25 um 11:34:38         | orb_messages.state_snapshot, orb_state                                                              | KAUSAL BEWIESEN                                                   |
| Thema „reisen“ bei einem Satz über Graphen               | Stamm wand trifft Schlüsselwort wander bei bidirektionalem Vergleich              | Knoten seit 19.09. mit Thema reisen; zwei eigene Fragen darauf | topicOf(), TOPIC_KEYWORDS, orb_nodes 1dfb5e07-..., Nachbau des Vergleichs                           | KAUSAL BEWIESEN                                                   |
| drei eigene Fragen am 21.09.                             | CURIOSITY-Zweig, Lücke aus Rangfolge, Gates erfüllt                               | Frage, Nachricht, Zustandsänderung, Metrik                     | orb_questions, orb_messages.proactive, orb_metrics.kind = proactive, impulse = null                 | KAUSAL BEWIESEN                                                   |
| Long-Term-Memory-Retrieval                               | Ähnlichkeit/Relevanz/Rangfolge über persistierte Knoten                           | Antwort nennt Inhalt vom 19.09. mit Stufe „wahrscheinlich“     | recall.ts, certaintyOf, recalled = 1, nodes_loaded                                                  | KAUSAL BEWIESEN                                                   |
| Persistenz persönlicher Angaben (19.09.)                 | importance 0.48 $\geq$ 0.35, Quelle user_stated                                   | Knoten 132bf051-..., später verbunden und abgerufen            | orb_messages, orb_nodes, orb_connections, orb_metrics                                               | KAUSAL BEWIESEN                                                   |
| 24 von 25 Ablehnungspunkten ohne Spur                    | silent(reason) ohne Protokoll, Client warf den Grund                              | Ablehnungen nachträglich nicht klassifizierbar                 | askProactively, frühere UI-Bedingung, fehlende Metrikzeilen                                         | KAUSAL BEWIESEN                                                   |
| „ORB denkt ...“ ohne sichtbare Folge                     | Hinweis gilt auch für eigenständige Versuche; bei asked = false bewusster Abbruch | Nutzer sieht Nachdenken, danach Stille                         | channels.orb.tsx (Abbruchbedingung, pending-Quelle), OrbChat.tsx                                    | KAUSAL BEWIESEN                                                   |
| Nachdenken-Zustand bleibt hängen                         | -                                                                                 | -                                                              | Zustand aus Anfragestatus abgeleitet, endet bei Erfolg und Fehler; Sprachschicht mit Zeitlimit      | WIDERLEGT                                                         |
| konkretes ablehnendes Gate um 11:30 UTC                  | ?                                                                                 | keine Frage                                                    | Versuchsanzeige nur sitzungslokal, keine Persistenz                                                 | OFFEN                                                             |
| Selbstkorrektur der Reise-Annahme                        | kein Mechanismus; asymmetrische Prompt-Zusammensetzung                            | zutreffende Richtigstellung im Antworttext                     | Prompt-Aufbau, Abwesenheit jeder Prüf- oder Nachverarbeitungsstelle                                 | DIREKT BEOBACHTET (Ereignis) / KAUSAL BEWIESEN (kein Mechanismus) |
| Abruf als <b>einzige</b> Quelle um 18:05:47 (19.09.)     | ?                                                                                 | Fakten korrekt genannt                                         | recalled = 1, aber Rohsatz lag auch im Kontextfenster                                               | WAHRSCHEINLICH                                                    |
| Teilpersistenz bei Fehler nach dem ersten Schreibvorgang | vier nicht transaktionale Schritte                                                | verwaiste Fragenzeile möglich                                  | Codelage in askProactively; kein Vorfall beobachtet                                                 | WAHRSCHEINLICH                                                    |

## 14. Technische Evidenz

| Befund                            | Datei / Funktion                                                                                                                                                                         | Datenquelle, Variable                      | DB-Objekt                                                                 | Zeitstempel                                   | Reproduzierbare r Test                                         | Erwartet                                          | Tatsächlich                                   |
|-----------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------|---------------------------------------------------------------------------|-----------------------------------------------|----------------------------------------------------------------|---------------------------------------------------|-----------------------------------------------|
| Energie-Zeitanker                 | src/orb-core/engine.server.ts — getSnapshot(), recordLearning(), toState(); src/orb-core/core.ts — recoverEnergy, clamp01, ENERGY_RECOVERY_PERCENT_MIN, ENERGY_RECOVERY_CAPACITY         | row.energy, row.updated_at                 | orb_state, Trigger orb_state_updated_at (BEFORE UPDATE, set_updated_at()) | 21.09. 06:30-11:34                            | tests/orb-energy-message-reset.test.ts (6 Tests, Fälle A-E)    | Erholung überdauert einen Zwischen Schreibvorgang | vor der Behebung: Erholung verfiel, Anzeige 0 |
| Energie-Gate                      | src/orb-core/curiosity.ts — decideCuriosity(), CURIOSITY_MIN_ENERGY = 0.15, CURIOSITY_ASK_THRESHOLD = 0.20                                                                               | input.energy, score                        | orb_state.energy                                                          | 21.09. 07:44 / 07:57                          | tests/orb-curiosity.test.ts (28 Tests)                         | WAIT unter 0.15                                   | WAIT, Grund „Zu wenig Energie“                |
| stay_silent unter 0.12            | src/orb-core/core.ts — decide(); src/orb-core/conversation.ts — FOLLOW_UP, SMALLTALK                                                                                                     | energy                                     | orb_messages.decision                                                     | 21.09. 07:44:26, 07:57:36                     | bestehende Konversationstests                                  | Antwort ohne eigenen Beitrag                      | decision = stay_silent, Modus LISTEN          |
| LISTEN ohne Wirkung auf Autonomie | src/orb-core/conversation.ts (ConversationMode, decideConversationMode, MODE_HINT); src/orb-core/llm/prompt.server.ts; src/orb-core/engine.server.ts — askProactively, formulateQuestion | mode                                       | keine Spalte vorhanden                                                    | 21.09.                                        | Suche über src/ nach LISTEN, decideConversationMode, MODE_HINT | kein Gate                                         | kein Gate; Modusfeld fehlt im Fragen-Prompt   |
| Themenklassifikation              | src/orb-core/memory.ts — topicOf(), TOPIC_KEYWORDS (Thema reisen enthält wander), Vergleich t.startsWith(k)    k.startsWith(t)                                                           | Wortstamm wand                             | orb_nodes.topic                                                           | Entstehung 19.09. 19:24:02, Entdeckung 21.09. | Nachbau der Funktion mit dem Originalsatz                      | Thema aus Satzinhalt                              | Thema reisen                                  |
| drei eigene Fragen                | src/orb-core/engine.server.ts — askProactively(), loadCuriosityContext(), formulateQuestion(), isDuplicateQuestion                                                                       | score, gap.kind, gap.topic, state_snapshot | orb_questions, orb_messages, orb_state, orb_metrics                       | 21.09. 08:45:30 / 08:54:27 / 08:59:57         | tests/orb-curiosity.test.ts, tests/orb-persistence.test.ts     | vollständige Persistenz                           | vollständig, alle beantwortet                 |
| Long-Term-Memory                  | src/orb-core/recall.ts, src/orb-core/continuity.ts — certaintyOf() (0.6 / 0.3)                                                                                                           | recalled, nodes_loaded                     | orb_nodes, orb_connections                                                | 19.09. 18:05:47 · 21.09. 08:59:13             | tests/orb-memory.test.ts, tests/orb-memory-recall-fix.test.ts  | Abruf persistierter Knoten                        | Abruf belegt, Stufe „wahrscheinlich“          |

| Befund             | Datei / Funktion                                                                                                                                                                                                        | Datenquelle, Variable                     | DB-Objekt | Zeitstempel  | Reproduzierbarer Test                    | Erwartet                     | Tatsächlich                                          |
|--------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------|-----------|--------------|------------------------------------------|------------------------------|------------------------------------------------------|
| Client-Gates       | src/orb-core/presence.ts — shouldAskProactively(), PROACTIVE_MIN_IDLE_MS = 40_000, PROACTIVE_MAX_IDLE_MS = 900_000, PROACTIVE_COOLDOWN_MS; src/integrations/y-dude-orb/use-orb-presence.ts (Intervall 5 s, Sofortsperr) | idleMs, curiosity, pending                | -         | 21.09.       | tests/orb-presence.test.ts (20 Tests)    | genau ein Aufruf je Freigabe | erfüllt                                              |
| Nachdenken-Zustand | src/routes/_authenticated/channels.orb.tsx (pending-Quelle, Abbruch bei !asked), src/components/orb/OrbChat.tsx (Hinweistext), src/orb-core/llm/openai.server.ts (AbortSignal.timeout)                                  | isPending, result.asked                   | -         | 21.09. 11:30 | Abgleich aller Erfolgs- und Fehlerzweige | Hinweis endet immer          | endet immer; kein sichtbarer Abschluss bei Ablehnung |
| Beobachtbarkeit    | src/components/orb/OrbDevPanel.tsx, src/routes/_authenticated/channels.orb.tsx (lastAutonomyAttempt)                                                                                                                    | asked, action, reason, topic, kind, score | -         | 21.09.       | Sichtprüfung im Testbereich              | letzter Versuch sichtbar     | sichtbar, nur sitzungslokal                          |

## 15. Was heute NICHT bewiesen wurde

1. Welches Gate den Versuch um 11:30 UTC ablehnte — Ablehnungen werden nicht persistiert. **OFFEN**
  2. Ob im beobachteten Ereignis überhaupt ein Serveraufruf erfolgte oder bereits ein clientseitiges Gate griff. **OFFEN**
  3. Der exakte Minutenverlauf der Energieanzeige — es wird kein Energieverlauf gespeichert; Zwischenwerte wurden ausdrücklich nicht rekonstruiert. **OFFEN**
  4. Ob der Abruf um 18:05:47 (19.09.) die **einzige** Quelle der genannten Fakten war; das Kontextfenster hätte den Rohsatz ebenfalls enthalten. **WAHRSCHEINLICH**
  5. Ob die beobachtete Selbstkorrektur wiederholbar ist; sie ist Modellverhalten ohne Prüfmechanismus. **OFFEN**
  6. Ob Teilpersistenz im eigenständigen Fragenweg praktisch aufgetreten ist; nur die Codelage erlaubt sie. **WAHRSCHEINLICH**
  7. Die exakte Commit-Kennung des veröffentlichten Production-Bündels — aus dem minimierten Bündel nicht ableitbar; belegt ist nur, dass die erwarteten Textbausteine enthalten sind. **OFFEN**
  8. Ob mehrere gleichzeitig geöffnete Ansichten in der Praxis zum Zeitanker-Verlust beitrugen; sie würden ihn nur häufiger auslösen, die Obergrenze bleibt eingehalten. **WAHRSCHEINLICH**
  9. Wie häufig eine falsche Themenzuordnung insgesamt auftritt; belegt ist ein Einzelfall und der Mechanismus, keine Häufigkeit. **OFFEN**
  10. Auswirkungen der Energie-Schwellen 0.12 und 0.20 auf Anschlussfragen, Smalltalk und Avatar-Darstellung im realen Mobilbetrieb. **OFFEN**
-

## 16. Abschlussbewertung

### KAUSAL BESTÄTIGT

1. Verlust des Erholungs-Zeitankers durch orb\_state-Schreibvorgänge ohne energy in Verbindung mit dem Zeitstempel-Trigger; Wirkung bis zur angezeigten Energie 0.
2. Anzeige-/Persistenz-Fehlpassung als Ursache des Abfalls von 11-15 % auf  $\approx 1$  %.
3. Energie unter 0.15 als Ursache ausbleibender eigener Fragen (WAIT).
4. Energie unter 0.12 als Ursache von stay\_silent und damit der LISTEN-Formulierung.
5. LISTEN ist kein ausführbares Hindernis für den eigenständigen Fragenweg (widerlegt).
6. Korrekte, zeitbasierte Energie-Erhholung mit live belegten Werten bis zur Obergrenze 0.25.
7. Falsche Themenzuordnung reisen durch bidirektionalen Wortstammvergleich, entstanden am 19.09.
8. Drei eigene Fragen am 21.09., alle über den CURIOSITY-Zweig, vollständig persistiert.
9. Long-Term-Memory-Retrieval persistierter Knoten mit berechneter Sicherheitsstufe.
10. Vollständige Kette Eingabe → Persistenz → Zustandsänderung → Abruf → Folgeverhalten (19.09.).
11. 24 von 25 Ablehnungspunkten ohne jede dauerhafte Spur.
12. Der Nachdenken-Hinweis kann nicht hängen bleiben; das beobachtete Muster entsteht durch den bewussten Abbruch bei asked = false.

### DIREKT BEOBACHTET

1. „ORB denkt ...“ ohne sichtbare Folge während des Live-Tests am 21.09. gegen 11:30 UTC.
2. Selbstkorrektur der Reise-Annahme im Antworttext.
3. Sichtbares Absinken der Energieanzeige ohne erkennbare Nutzeraktion.
4. Der zuvor im Testbereich beobachtete abgelehnte Versuch mit Wert 0.643.

### OFFEN

1. Konkretes ablehnendes Gate des Ereignisses um 11:30 UTC.
2. Minutenverlauf der Energieanzeige.
3. Exklusivität des Abrufs als Faktenquelle am 19.09. um 18:05:47.
4. Wiederholbarkeit der Selbstkorrektur.
5. Häufigkeit falscher Themenzuordnungen.
6. Praktische Auswirkungen der Schwellen 0.12 und 0.20 im Mobilbetrieb.
7. Commit-Kennung des veröffentlichten Bündels.
8. Tatsächliches Auftreten von Teilpersistenz im eigenständigen Fragenweg.

---

Source reports analyzed: 15 Causally confirmed findings: 12 Observed-only findings: 4 Probable findings: 4 Open findings: 8 Files changed in application: 0 Database changes: 0 Migrations: 0 Deployments: 0 Configuration changes: 0 Tests changed: 0