

ORB CORE

FORENSIC MASTER REPORT

Konsolidierung aller ORB-Core-Forensikberichte vom 21. September 2026 – Ausgabe mit Kausalitätsnachweis

Datum	2026-09-21
Version	1.0
Umgebung	Production
Modus	READ-ONLY Quellenanalyse – keine Codeänderung
Quellberichte	15
Klassifikation	KAUSAL BEWIESEN · DIREKT BEOBACHTET · WAHRSCHEINLICH · OFFEN

Inhaltsverzeichnis

ORB CORE — FORENSIC MASTER REPORT

Evidenzklassifikation

Quellenberichte (15)

1. Executive Summary

2. Ausgangslage

3. Autonomous Question Path

4. Energy Forensics

4.1 Drei Energiebegriffe

4.2 Belegte Energie-Abflüsse

4.3 Live-Werte

4.4 Der Abfall 11-15 % → 1 %

4.5 Behebung (dokumentiert, außerhalb dieses Berichts erfolgt)

5. LISTEN / Autonomous Path

6. Observability

6.1 Forensischer Befund

6.2 Umgesetzte Änderung (dokumentiert, außerhalb dieses Berichts erfolgt)

6.3 Fortbestehende Grenzen

7. Memory Recall

7.1 Belegte Persistenz (Case 2, 19.09.2026)

7.2 Abgrenzungen

8. Die „Reisen“-Fehlverknüpfung

9. Selbstkorrektur

10. Die drei eigenen Fragen des 21.09.

11. „ORB denkt ...“ — Forensik

11.1 Lebenszyklus des Nachdenken-Zustands

11.2 Alle Fehlerpfade

11.3 Ergebnis

12. Cross-System Causality

13. Kausalitätstabelle

14. Technische Evidenz

15. Was heute NICHT bewiesen wurde

16. Abschlussbewertung

KAUSAL BESTÄTIGT

DIREKT BEOBACHTET

OFFEN

ORB CORE — FORENSIC MASTER REPORT

Datum: 2026-09-21 · Version: 1.0 · Umgebung: Production · Modus: READ-ONLY Quellenanalyse

Zusammenführung aller am 2026-09-21 erstellten oder aktualisierten ORB-Core-Forensik-, Audit- und Untersuchungsberichte. Keine Codeänderung, keine Datenbankänderung, keine Migration, keine Konfigurationsänderung, keine Teständerung, kein Deployment im Rahmen dieses Berichts.

Evidenzklassifikation

Status	Bedeutung
KAUSAL BEWIESEN	Ursache → Wirkung technisch nachvollzogen und durch Code, DB-Zeilen, Trigger, Test oder Laufzeitdaten belegt
DIREKT BEOBACHTET	Ereignis sicher belegt, vollständige Ursache nicht bewiesen
WAHRSCHEINLICH	technisch plausibel, kein vollständiger Kausalitätsnachweis
OFFEN	keine ausreichende Evidenz

Quellenberichte (15)

#	Bericht	Gegenstand
1	ORB_ENERGY_RECOVERY_DESIGN_SIMULATION_2026-09-21.md	Entwurf und Simulation der Energie-Erholung
2	ORB_ENERGY_RECOVERY_IMPLEMENTATION_PRODUCTION_2026-09-21.md	freigegebene Umsetzung +0.02/min, Cap 0.25
3	ORB_PROACTIVE_QUESTIONING_BLOCK_ANALYSIS_2026-09-21.md	Blockade eigener Fragen, Energie als Sperre
4	ORB_PROACTIVE_COUNTERFACTUAL_SIMULATION_2026-09-21.md	Gegenprobe der Gates
5	ORB_LISTEN_AUTONOMY_FORENSIC_2026-09-21.md	LISTEN als Prompt-Wortlaut, nicht als Sperre
6	ORB_ENERGY_FORENSIC_LIVE_EVENT_2026-09-21.md	Live-Abfall 11-15 % → 1 %
7	ORB_AUTONOMY_OBSERVABILITY_FORENSIC_2026-09-21.md	25 Gates, stille Ablehnungen
8	ORB_AUTONOMY_OBSERVABILITY_IMPLEMENTATION_2026-09-21.md	Testbereich-Anzeige des letzten Versuchs
9	ORB_AUTONOMY_OBSERVABILITY_UI_VISIBILITY_CHECK_2026-09-21.md	Auffindbarkeit der Anzeige
10	ORB_FORENSIC_CASE2_PERSONAL_MEMORY_2026-09-21.md	Persistenz und Abruf persönlicher Angaben (19.09.)
11	ORB_CROSS_CASE_AUTONOMY_ARCHITECTURE_2026-09-21.md	Vergleich Curiosity- und Impuls-Zweig
12	ORB_FORENSIC_MEMORY_RECALL_AUTONOMY_2026-09-21.md	drei eigene Fragen, Reisen-Fehlverknüpfung, Selbstkorrektur
13	ORB_ENERGY_MESSAGE_RESET_FIX_2026-09-21.md	Ursache und minimale Behebung des Energie-Rücksetzers
14	ORB_CORE_OBJECTIVE_MATURITY_ASSESSMENT_2026-09-21.md	Reifegrad-Bestandsaufnahme
15	ORB_THINKING_STUCK_FORENSIC_2026-09-21.md	„ORB denkt ...“ ohne sichtbare Folge

1. Executive Summary

Fünf Ursache-Wirkungs-Ketten wurden heute vollständig belegt.

1. Energie-Erholung wurde durch fremde Zustandsschreibvorgänge neutralisiert (KAUSAL BEWIESEN). Der angezeigte Energiewert wird zur Laufzeit als gespeicherter Wert + $\Delta t \cdot 0.02$ berechnet, wobei Δt aus `orb_state.updated_at` stammt. Zwei nicht energiebezogene Schreibvorgänge — `decay_computations` in `getSnapshot()` und der Lernzähler in `recordLearning()` — schrieben `orb_state` ohne `energy`. Der Trigger `orb_state_updated_at` setzte dabei `updated_at = now()`. Damit war Δt wieder nahe 0, die aufgelaufene Erholung verfiel, und die anschließenden Nachrichtenkosten wurden auf einen nicht erhaltenen Wert angewandt; `clamp01()` ergab exakt 0.

2. Die Blockade eigener Fragen war ein Energie-Gate, nicht LISTEN (KAUSAL BEWIESEN). `decideCuriosity()` liefert `WAIT`, sobald `energy < 0.15`. Der Modus `LISTEN` existiert nur als Antwort-Etikett und als ein Satz Prompt-Wortlaut; im eigenständigen Fragenweg wird er nicht gelesen und nicht einmal in den Prompt übergeben.

3. Die Energie-Erholung arbeitet zur Laufzeit korrekt (KAUSAL BEWIESEN, live reproduziert). Live-Werte aus `orb_messages.state_snapshot`: 0.00696 → 0.19096 → 0.18070 → 0.21162; nach der Behebung von Punkt 1 wurde um 11:34:38 UTC der gespeicherte Wert 0.25 erreicht — die Obergrenze.

4. Die „Reisen“-Fehlverknüpfung entstand beim Memory-Ingest am 19.09. (KAUSAL BEWIESEN). `topicOf()` vergleicht Wortstämme in beide Richtungen. Der Stamm `wand` aus „wandern“ trifft das Reise-Schlüsselwort `wander`. Der Knoten wurde deshalb am 19.09. mit dem Thema `reisen` gespeichert. Das Sprachmodell erhielt am 21.09. eine bereits falsch klassifizierte Erinnerung.

5. Long-Term-Memory-Retrieval ist belegt (KAUSAL BEWIESEN). Ein am 19.09. persistierter Knoten wurde am 21.09. über Ähnlichkeit, Relevanz und Rangfolge geladen und mit berechneter Sicherheitsstufe „wahrscheinlich“ (Schwelle 0.3 / 0.6) in die Antwort übernommen.

Direkt beobachtet, aber ursächlich nicht abgeschlossen: das Muster „ORB denkt ... danach nichts“. Belegt ist, dass der Nachdenken-Hinweis technisch nicht hängen bleiben kann und dass eine Ablehnung bewusst ohne sichtbaren Abschluss endet. Welches Gate im konkreten Ereignis um 11:30 UTC ablehnte, ist OFFEN, weil Ablehnungen nicht persistiert werden.

Nicht als Mechanismus bestätigt: die beobachtete Selbstkorrektur. Es existiert kein Prüfschritt, der Themenplausibilität oder die Voraussetzung einer früheren eigenen Frage gegen den Abruf hält.

2. Ausgangslage

Stand zu Tagesbeginn (2026-09-21, 06:30 UTC):

- Die Energie-Erholung (+0.02/Minute, Obergrenze 0.25, Kosten einer eigenen Frage 0.03) war am Vortag freigegeben und in Production veröffentlicht. Der gespeicherte Energiewert lag bei 0.
 - Es existierten 0 eigene Fragen des laufenden Tages; der letzte proactive-Metrikeintrag stammte vom 2026-09-20 07:26:13.
 - Das Verhalten „ORB stellt keine eigenen Fragen mehr“ war offen und wurde von ORB selbst mit „LISTEN-Vorgaben“ begründet.
 - Der Energiewert der Anzeige schwankte sichtbar ohne erkennbare Nutzeraktion.
-

3. Autonomous Question Path

Nur tatsächlich im Code belegte Komponenten. Dateien und Zeilen in Kapitel 14.

```
Browser: Leerlauf-Beobachter (use-orb-presence.ts, Intervall 5 s, rein rechnerisch)
G1 Tab sichtbar
G2 kein Tippen
G3 Mikrofon inaktiv
G4 ORB spricht nicht
G5 keine laufende Anfrage (pending)
G6 Leerlauf >= 40 s
G7 Leerlauf <= 15 min
G8 Neugier-Band != low
G9 Client-Cooldown (low/medium 300 s, high 180 s, very_high 120 s)
  -> Sofortsperr lastProactiveRef = now (verhindert Doppelaufruf)
  -> genau EIN Serveraufruf: requestOrbCuriosity
Server: askProactively(db, userId)
  loadCuriosityContext: 12 Knoten, 8 Interessen, 8 Nachrichten, Fragenhistorie, 60 Verbindungen
  CURIOSITY-Zweig decideCuriosity()
    G10 mindestens eine Wissenslücke
    G11 Neugier ausreichend (mayAskAtCuriosity)
    G12 energy >= 0.15 -> sonst WAIT
    G13 keine offene eigene Frage -> sonst WAIT
    G14 Server-Cooldown -> sonst WAIT
    G15 Kandidatenwert >= 0.20 -> sonst WAIT
  IMPULSE-Zweig decideImpulse()
    Suppression, offene Frage, Duplikat/bekannt, Priorität, Wert >= 0.20
  Merge: impulse ? gapFromImpulse(...) : decision.gap
  Formulation: formulateQuestion() -> Sprachschicht (Zeitlimit per AbortSignal)
    -> Statusfehler = still
  Duplikatprüfung: isDuplicateQuestion (Ähnlichkeitsschwelle 0.6) -> still
  Persistenz (vier Schreibvorgänge, nicht transaktional):
    orb_questions -> orb_messages (state_snapshot.proactive = true, question_id)
    -> orb_state (curiosity -0.06, energy -0.03) -> orb_metrics kind = 'proactive'
  Rückgabe: asked = true, Frage, Snapshot
UI: curiosityMutation.onSuccess
  Versuch wird immer in die Testbereich-Anzeige geschrieben
  bei asked = false: bewusster Abbruch, keine Chat-Ausgabe
  bei asked = true: Snapshot, Chat-Zeile, optional Sprachausgabe, Cooldown
```

Belegte Eigenschaften dieses Pfades:

- Die Entscheidung *ob* und *worüber* gefragt wird, ist deterministisch; nur die Formulierung stammt aus der Sprachschicht. **KAUSAL BEWIESEN**
- Der Takt liegt ausschließlich im Browser; ohne geöffnete ORB-Ansicht existiert kein eigenständiger Fragenweg. **KAUSAL BEWIESEN**
- Die vier Persistenzschritte sind nicht in einer Transaktion gebündelt; ein Fehler nach dem ersten Schritt kann eine Fragenzeile ohne Nachricht hinterlassen. **WAHRSCHEINLICH** (Codelage belegt, kein Vorfall beobachtet)

4. Energy Forensics

4.1 Drei Energiebegriffe

Begriff	Definition	Ort
STORED	Spaltenwert orb_state.energy	Datenbank
CALCULATED	$\text{recoverEnergy}(\text{stored}, \text{updated_at}, \text{now}) = \min(0.25, \text{stored} + \Delta t \cdot 0.02)$	toState() zur Laufzeit
DISPLAYED	CALCULATED, gerundet in Prozent; steuert zusätzlich die Avatar-Darstellung ab 0.20	Oberfläche

KAUSAL BEWIESEN: Der angezeigte Wert war nie der gespeicherte Wert. Der Zeitanker der Erholung ist kein eigenes Feld, sondern orb_state.updated_at.

4.2 Belegte Energie-Abflüsse

Quelle	Betrag	Beleg
normale Nachricht (Zustandsverfall in processInput)	zustandsabhängig	state_snapshot.energy je Turn
gestellte eigene Frage	-0.03	askProactively, Zustandsupdate
sonstige Verbraucher	keine gefunden	Suche über alle orb_state-Schreibpfade

Abgelehnte Versuche, Rendern, der Nachdenken-Hinweis, Abfragen und LISTEN verbrauchen **keine** Energie. **KAUSAL BEWIESEN**

4.3 Live-Werte

Quelle: orb_messages.state_snapshot.energy (Production, Nutzer 9ce1d1b0-...).

Zeit (UTC)	Wert	Bedeutung
08:36:16	0.00696	Ausgangswert nach dem Rücksetz-Effekt, kurz vor der ersten eigenen Frage
08:45:30	0.19096	Snapshot der eigenen Frage A — Erholung erstmals zur Laufzeit belegt
08:54:27	0.18070	Snapshot der eigenen Frage B, nach Kosten 0.03 und erneuter Erholung
08:59:57	0.21162	Snapshot der eigenen Frage C
11:19-11:22	0.206 → 0.103	Absinken durch mehrere aufeinanderfolgende Nachrichten
11:30:17	0.208	Erholung nach Gesprächspause
11:34:38	0.25 (STORED)	Obergrenze erreicht; erstmals ist auch der gespeicherte Wert erholt

Die Reihe 0.007 → 0.191 → 0.181 → 0.212 ist damit nicht eine Messung derselben Größe in gleichen Abständen, sondern die Energie **zum Zeitpunkt von vier verschiedenen Ereignissen**: einem normalen Turn und den drei eigenen Fragen.

4.4 Der Abfall 11-15 % → 1 %

KAUSAL BEWIESEN: Anzeige-/Persistenz-Fehlpassung. Ausgeschlossen wurden wiederholte legitime Kosten (heute 2 Nachrichten, 0 Fragen), ein unbekannter Verbraucher (keiner existiert) und mehrfache autonome Zyklen (0 proactive-Metriken zum Zeitpunkt der Analyse). Ursache ist, dass getSnapshot() bei jedem Abruf decay_computations schrieb; der Trigger setzte updated_at = now(), Δt fiel auf 0, und die Anzeige sprang auf ≈ 0–1 % zurück. decay_computations stand bei 4539 — jeder dieser Schreibvorgänge hatte denselben Effekt.

4.5 Behebung (dokumentiert, außerhalb dieses Berichts erfolgt)

Beide Schreibvorgänge schreiben seither zusätzlich energy: toState(stateRow).energy, also den zum Lesezeitpunkt erhaltenen Wert; der neue Zeitstempel gehört damit zum neuen Basiswert. Unverändert: Kosten, Rate +0.02/min, Obergrenze 0.25, Schwelle 0.15, alle Gates, Schema und RLS. Belegt durch 6 neue Tests sowie 1095 Logik- und 77 DB/Security-Tests.

5. LISTEN / Autonomous Path

KAUSAL BEWIESEN:

- LISTEN existiert an genau drei Stellen: als Wert von ConversationMode, als Rückfallzweig von decideConversationMode() und als Eintrag in MODE_HINT („stelle keine Frage“).
- Es gibt keine LISTEN-Spalte in orb_state und keinen LISTEN-Zustand, der aktiv sein könnte.
- decideConversationMode() wird ausschließlich im Antwortweg (processInput) aufgerufen.
- askProactively() liest ConversationMode nicht; formulateQuestion() baut einen eigenen Prompt **ohne** Modusfeld. MODE_HINT.LISTEN erreicht den eigenständigen Fragenweg nicht.
- Der einzige ausführbare Effekt von LISTEN ist, dass für die Antwort Gesprächsfäden und Fokusthema geleert werden.

Entstehung der früheren Fehlinterpretation (KAUSAL BEWIESEN): ORB selbst hatte formuliert, „LISTEN-Vorgaben verbieten mir, eine Frage zu stellen“. Diese Aussage ist Modelltext. Technisch entschied die Energie: beide betroffenen Antworten tragen decision = stay_silent, und decide() liefert stay_silent, sobald energy < 0.12. FOLLOW_UP und SMALLTALK verlangen ebenfalls energy >= 0.12. LISTEN war die Folge niedriger Energie, nicht deren Ursache.

6. Observability

6.1 Forensischer Befund

KAUSAL BEWIESEN: Der eigenständige Fragenweg hatte 25 Entscheidungspunkte, von denen 24 vollständig still waren. Clientseitig (G1–G9) verlässt die Begründung den Browser nie; sie lag nur in React-State. Serverseitig gibt `silent(reason)` ein einfaches Objekt zurück — keine Protokollzeile, keine Metrik, keine Fragen-, Nachrichten- oder Zustandszeile. Nur der tatsächlich gesendete Fall hinterlässt eine dauerhafte Spur (`orb_questions + orb_messages.state_snapshot.proactive + orb_metrics` `kind = 'proactive' + Energie -0.03`). Ein geworfener Datenbankfehler war ausschließlich in der Browserkonsole sichtbar.

Nicht rekonstruierbar waren damit: ob der Beobachter überhaupt auslöste, welches der 16 serverseitigen Gates ablehnte, der Energiewert im Entscheidungsmoment, der Kandidatenwert einer Ablehnung, die Anzahl der Versuche einer Sitzung und ob die Sprachschicht ausfiel.

6.2 Umgesetzte Änderung (dokumentiert, außerhalb dieses Berichts erfolgt)

Reine Client-Anzeige: der vom Server ohnehin zurückgegebene Grund des letzten Versuchs wird im bestehenden Testbereich als „Letzter eigener Fragen-Versuch“ dargestellt (Zeitpunkt, asked, Aktion, Grund, Thema, Lückenart, Wert). Keine Änderung an Entscheidung, Schwellen, Energie, Persistenz, Datenbank, Anfragen, Zeitgebern oder Server.

6.3 Fortbestehende Grenzen

- Die Anzeige ist sitzungslokal und nach einem Neuladen verloren. **KAUSAL BEWIESEN**
- Ein ausgebliebener Versuch bleibt unklassifiziert (nicht ausgelöst oder clientseitig abgelehnt).

KAUSAL BEWIESEN

- Der Abschnitt liegt hinter zwei standardmäßig geschlossenen Ebenen (Technische Informationen → Status) und unterhalb des sichtbaren Bereichs; es existiert kein Entwickler-, Admin-, Umgebungs- oder Feature-Schalter davor. **KAUSAL BEWIESEN**

- Fehler des eigenständigen Weges gehen weiterhin nur in die Browserkonsole. **KAUSAL BEWIESEN**
-

7. Memory Recall

7.1 Belegte Persistenz (Case 2, 19.09.2026)

Zeit (UTC)	Ereignis	Beleg
18:04:31.688	Nutzeraussage mit Lieblingsessen, Getränk, Schuhgröße 42, Grafikkarte RTX 5070	orb_messages b610a162-...
18:04:31.689	Modellantwort „... merke ich mir ...“, recalled = 0	orb_messages ff3cb09b-...
18:04:35.100	Persistenz eines Knotens mit dem Rohsatz , importance 0.48 $\geq$ Schwelle 0.35, confidence 0.9, user_stated, active	orb_nodes 132bf051-...
18:05:12.998	eigener Beitrag ohne neue Nutzereingabe, decision = ask, Curiosity-Zweig, gap_kind detail, score 0.40446	orb_questions 145b70ef-...
18:05:47.846	Abruf: Fakten korrekt genannt, recalled = 1, nodes_loaded = 3	orb_messages 3fdce42f-...
18:05:51.729	Zustandsänderung: erste Verbindung 132bf051 → 4e4167ac	orb_connections 283725f0-...

KAUSAL BEWIESEN: Eingabe → Erkennung → Entscheidung → Persistenz → Zustandsänderung → Abruf → Folgeverhalten. Die Modellaussage „merke ich mir“ entstand **vor** der Persistenz und ist kein Persistenznachweis. Es wurden keine vier Einzelfakten gespeichert, sondern eine Äußerung.

7.2 Abgrenzungen

- **Gesprächskontext:** Der Antwortweg lädt bis zu acht der letzten Nachrichten. Für die Antwort um 18:04:31 ist recalled = 0 belegt — sie stammte ausschließlich aus dem Kontextfenster. **KAUSAL BEWIESEN**

- Für 18:05:47 ist Abruf belegt (recalled = 1), der Rohsatz lag aber ebenfalls noch im Kontextfenster; die **Exklusivität** des Abrufs als Quelle ist an dieser Stelle nicht bewiesen.

WAHRSCHEINLICH

- **Graph:** Verbindungen beeinflussen Relevanz und den Impuls-Zweig. Der Curiosity-Lückenweg nutzt sie nicht direkt; Gesprächsfäden werden vom eigenständigen Fragenweg nicht geladen. **KAUSAL BEWIESEN**

- **Long-Term-Memory-Retrieval am 21.09.:** Der am 19.09. um 19:24:02 angelegte Knoten 1dfb5e07-... (importance 0.72, activation_count 16) wurde am 21.09. über Ähnlichkeit, Relevanz und Rangfolge geladen. Die Formulierung „wahrscheinlich“ entstammt der berechneten Sicherheitsstufe (certainty0f: „sicher“ ab 0.6, „wahrscheinlich“ ab 0.3). Das Anzeigetikett „ERINNERN“ ist die Darstellung der Entscheidung remind. **KAUSAL BEWIESEN**

8. Die „Reisen“-Fehlverknüpfung

Entstehungszeitpunkt: **2026-09-19, 19:24:02 UTC** · Entdeckungszeitpunkt: **2026-09-21**

Kausalkette, vollständig reproduziert:

Nutzertext: „... keine Zeit in den Graphen zu wandern“
-> Tokenisierung/Stammbildung ergibt u. a. den Stamm wand
-> topicOf() vergleicht bidirektional: t.startsWith(k) || k.startsWith(t)
-> Themenschlüsselwort des Themas „reisen“ enthält wander
-> "wander".startsWith("wand") ist wahr
-> Thema des Knotens wird reisen
-> Persistenz am 19.09. 19:24:02 als orb_nodes 1dfb5e07-... (topic = reisen)
-> 21.09.: Rangfolge wählt diesen Knoten als Wissenslücke
-> eigene Frage A (08:45:30) und B (08:54:27) mit Thema reisen
-> Nutzerantwort über Griechenland (08:51:42) verstärkt die Themenspur

Status: KAUSAL BEWIESEN. Ausdrücklich festgehalten:

- Die Fehlklassifikation entstand beim Memory-Ingest, nicht bei der späteren Textausgabe.
 - Sie entstand am 19.09., nicht am 21.09.
 - Das Sprachmodell erhielt eine bereits falsch klassifizierte Erinnerung; es hat nicht zwei Erinnerungen vermischt und keine Reiseinformation erfunden.
 - Der betroffene Knoteninhalt lautet wörtlich: „Okay ich sehe das problem. Der Chatverlauf ist zu kurz. Und die wichtigen Informationen haben keine Zeit in den Graphen zu wandern“.
 - Ein Konfidenzwert für die Themenzuordnung existiert nicht; ein falsches Thema ist daher von einem richtigen nicht unterscheidbar.
-

9. Selbstkorrektur

Beobachtet: ORB stellte später fest, dass ein konkreter Bezug zu Reisen in den betreffenden Erinnerungen nicht enthalten ist.

Belegt (KAUSAL BEWIESEN):

- Es existiert kein Codeabschnitt, der die Plausibilität eines Themas prüft.
- Es existiert kein Codeabschnitt, der die Voraussetzung einer früheren eigenen Frage gegen den Abruf hält, und keine Nachverarbeitung der Antwort.
- Der Antwort-Prompt erhält den Erinnerungstext, **ohne** das Thema zu behaupten; der Frage-Prompt erhält das Themen-Etikett. Diese Asymmetrie ermöglichte die Korrektur.

Klassifikation: LLM-basierte Selbstkorrektur, ermöglicht durch asymmetrische Prompt-Zusammensetzung. Kein nachgewiesener eigener Validierungsmechanismus und keine Quellenzuordnung. Eine Wiederholbarkeit ist nicht garantiert. **DIREKT BEOBACHTET** für das Ereignis, **KAUSAL BEWIESEN** für die Abwesenheit eines Mechanismus.

10. Die drei eigenen Fragen des 21.09.

	Frage A	Frage B	Frage C
Fragenzeile (orb_questions)	08:45:30.976	08:54:27.211	08:59:57.407
Nachricht / Metrik	08:45:33	08:54:30	09:00:01
Thema	reisen	reisen	hardware
Lückenart	detail	kontext	erfahrung
Wert	0.6425	0.6806	0.5995
Quellknoten	1dfb5e07-...	1dfb5e07-...	59d932de-...
Energie im Snapshot	0.19096	0.18070	0.21162
Neugier-Band	very_high	very_high	very_high
Weg	CURIOSITY	CURIOSITY	CURIOSITY
state_snapshot.proactive	true	true	true
impulse im Snapshot	null	null	null
Persistenz	vollständig (Frage, Nachricht, Zustand, Metrik)	vollständig	vollständig
Ergebnis	beantwortet	beantwortet	beantwortet

KAUSAL BEWIESEN: Alle drei liefen über den CURIOSITY-Zweig, keine über IMPULSE (Nachweis: `impulse = null` im Snapshot jeder Zeile). Zwei aufeinanderfolgende Fragen stammen aus **einem** Knoten, weil die Lückenart wechselte (`detail` → `kontext`) und der Lückenschlüssel Knoten und Lückenart kombiniert. Ein früher im Testbereich beobachteter abgelehnter Versuch trug denselben Wert 0.643 wie die später gestellte Frage A — es fehlte ausschließlich die Energie.

Ergänzend belegt für den 21.09. nach 09:00: weitere eigene Fragen um 09:31:19, 09:36:43, 09:47:46, 10:47:22 und 10:49:57, alle beantwortet; danach keine weitere bis 11:36.

11. „ORB denkt ...“ — Forensik

11.1 Lebenszyklus des Nachdenken-Zustands

KAUSAL BEWIESEN: Es gibt keinen eigenen Zustandsschalter. Der Hinweis wird aus `sendMutation.isPending || curiosityMutation.isPending` abgeleitet und an drei Stellen angezeigt (Chatverlauf, Statuszeile, Gesicht). Folgen:

1. Start: automatisch mit dem Auslösen der Anfrage — also **vor** dem Serveraufruf.
2. Ende: automatisch beim Abschluss der Anfrage, bei Erfolg **und** bei Fehler.
3. Es existiert kein Rücksprung, der einen Schalter offen lassen könnte; ein `finally` ist nicht erforderlich.

11.2 Alle Fehlerpfade

Fall	Verhalten	Nachdenken endet	Sichtbarer Abschluss
Gate lehnt ab (<code>silent</code>)	HTTP 200, <code>asked = false</code> , Grund im Ergebnis	ja	nein (bewusst)
Persistenzfehler (geworfene Ausnahme)	Fehlerzweig, nur Browserkonsole	ja	nein
Netzwerkfehler / HTTP $\neq$ 200 / defektes JSON	Fehlerzweig, kein Wiederholungsversuch	ja	nein
Sprachschicht hängt	ausgeschlossen: Zeitlimit per <code>AbortSignal.timeout</code>	ja	nein
Komponente wird verlassen	Ergebnis verworfen, Zustand existiert nicht mehr	entfällt	entfällt
Zwei gleichzeitige Versuche	verhindert durch <code>pending</code> -Gate und Sofortsperr	ja	entfällt

11.3 Ergebnis

KAUSAL BEWIESEN: Der Nachdenken-Hinweis erscheint auch für einen eigenständigen Versuch und zwar vor der Serverantwort; bei `asked = false` bricht die Oberfläche bewusst ohne Chat-Ausgabe, Meldung oder Hinweis ab. Das erzeugt genau das beobachtete Muster, obwohl der Ablauf korrekt und vollständig beendet ist.

OFFEN: Welches Gate im Ereignis um 11:30 UTC ablehnte. Zum Zeitpunkt der Analyse waren Energie 0.25, keine offene Frage und der Server-Cooldown erfüllt; die sitzungslokale Versuchsanzeige war nicht mehr vorhanden. Ein hängender Nachdenken-Zustand wurde **nicht** nachgewiesen; es wurde deshalb nichts geändert.

12. Cross-System Causality

KETTE 1 – Energie-Zeitanker

Snapshot-Abruf / Lernzähler schreibt orb_state ohne energy
-> Trigger orb_state_updated_at setzt updated_at = now()
-> $\Delta t = 0 \Rightarrow$ CALCULATED = STORED (niedrig)
-> Nachrichtenkosten auf nicht erhaltenen Wert -> clamp01 = 0
-> DISPLAYED springt auf 0 [KAUSAL BEWIESEN]

KETTE 2 – Autonomie-Sperre

energy < 0.15 -> decideCuriosity = WAIT -> asked = false
-> keine Frage, keine Spur, kein sichtbarer Abschluss [KAUSAL BEWIESEN]

KETTE 3 – Erholung ermöglicht eigene Frage

Ruhezeit -> +0.02/min (Cap 0.25) -> Schwelle 0.15 erreicht
-> Kandidatenwert 0.643 >= 0.20 -> Frage A 08:45:30 [KAUSAL BEWIESEN]

KETTE 4 – Themenklassifikation

"wandern" -> Stamm "wand" -> bidirektionaler Vergleich mit "wander"
-> Thema reisen -> Persistenz 19.09. -> Retrieval 21.09.
-> eigene Fragen A und B mit Thema reisen [KAUSAL BEWIESEN]

KETTE 5 – Long-Term-Memory

persistierter Knoten -> Ähnlichkeit/Relevanz/Rangfolge
-> Antwortkontext -> Sicherheitsstufe "wahrscheinlich" [KAUSAL BEWIESEN]

KETTE 6 – LISTEN

energy < 0.12 -> decide() = stay_silent -> Modus LISTEN
-> Prompt-Wortlaut "stelle keine Frage"
-> Modellaussage "LISTEN verbietet mir zu fragen" [KAUSAL BEWIESEN]
(LISTEN -> Blockade des eigenständigen Weges) [WIDERLEGT]

13. Kausalitätstabelle

Befund	Ursache	Wirkung	Evidenz	Status
Energie erscheint nach einer Nachricht als 0	orb_state-Schreibvorgänge ohne energy + Trigger auf updated_at	$\Delta t = 0$, Erholung verfällt, clamp01 ergibt 0	engine.server.ts (Snapshot- und Lernpfad), toState, Trigger orb_state_updated_at, DB-Zeile energy 0	KAUSAL BEWIESEN
Anzeige fiel von 11-15 % auf ≈ 1 %	derselbe Zeitanker-Verlust bei jedem Snapshot-Abwurf	Anzeigesprung ohne Nutzeraktion	decay_computations = 4539, keine Kosten- oder Verbraucherzeile	KAUSAL BEWIESEN
keine eigenen Fragen am Morgen	energy < 0.15	decideCuriosity = WAIT	curiosity.ts Gate, decision = stay_silent, 0 proactive-Metriken	KAUSAL BEWIESEN
ORB nannte LISTEN als Verbot	Energie < 0.12 → stay_silent → Modus LISTEN → Prompt-Wortlaut	Modelltext mit falscher technischer Begründung	conversation.ts, core.ts decide(), prompt.server.ts	KAUSAL BEWIESEN
LISTEN blockiert eigene Fragen	-	-	askProactively liest den Modus nicht; formulateQuestion übergibt kein Modusfeld	KAUSAL BEWIESEN (Annahme widerlegt)
Energie-Erholung funktioniert	reine Zeitfunktion recoverEnergy	0.007 → 0.191 → 0.181 → 0.212; STORED 0.25 um 11:34:38	orb_messages.state_snapshot, orb_state	KAUSAL BEWIESEN
Thema „reisen“ bei einem Satz über Graphen	Stamm wand trifft Schlüsselwort wander bei bidirektionalem Vergleich	Knoten seit 19.09. mit Thema reisen; zwei eigene Fragen darauf	topicOf(), TOPIC_KEYWORDS, orb_nodes 1dfb5e07-..., Nachbau des Vergleichs	KAUSAL BEWIESEN
drei eigene Fragen am 21.09.	CURIOSITY-Zweig, Lücke aus Rangfolge, Gates erfüllt	Frage, Nachricht, Zustandsänderung, Metrik	orb_questions, orb_messages.proactive, orb_metrics kind = proactive, impulse = null	KAUSAL BEWIESEN
Long-Term-Memory-Retrieval	Ähnlichkeit/Relevanz/Rangfolge über persistierte Knoten	Antwort nennt Inhalt vom 19.09. mit Stufe „wahrscheinlich“	recall.ts, certaintyOf, recalled = 1, nodes_loaded	KAUSAL BEWIESEN
Persistenz persönlicher Angaben (19.09.)	importance 0.48 $\geq$ 0.35, Quelle user_stated	Knoten 132bf051-..., später verbunden und abgerufen	orb_messages, orb_nodes, orb_connections, orb_metrics	KAUSAL BEWIESEN
24 von 25 Ablehnungspunkten ohne Spur	silent(reason) ohne Protokoll, Client warf den Grund	Ablehnungen nachträglich nicht klassifizierbar	askProactively, frühere UI-Bedingung, fehlende Metrikzeilen	KAUSAL BEWIESEN
„ORB denkt ...“ ohne sichtbare Folge	Hinweis gilt auch für eigenständige Versuche; bei asked = false bewusster Abbruch	Nutzer sieht Nachdenken, danach Stille	channels.orb.tsx (Abbruchbedingung, pending-Quelle), OrbChat.tsx	KAUSAL BEWIESEN
Nachdenken-Zustand bleibt hängen	-	-	Zustand aus Anfragestatus abgeleitet, endet bei Erfolg und Fehler; Sprachschicht mit Zeitlimit	KAUSAL BEWIESEN (Annahme widerlegt)
konkretes ablehnendes Gate um 11:30 UTC	?	keine Frage	Versuchsanzeige nur sitzungslokal, keine Persistenz	OFFEN
Selbstkorrektur der Reise-Annahme	kein Mechanismus; asymmetrische Prompt-Zusammensetzung	zutreffende Richtigstellung im Antworttext	Prompt-Aufbau, Abwesenheit jeder Prüf- oder Nachverarbeitungsstelle	DIREKT BEOBACHTET (Ereignis) / KAUSAL BEWIESEN (kein Mechanismus)
Abwurf als einzige Quelle um 18:05:47 (19.09.)	?	Fakten korrekt genannt	recalled = 1, aber Rohsatz lag auch im Kontextfenster	WAHRSCHEINLICH
Teilpersistenz bei Fehler nach dem ersten Schreibvorgang	vier nicht transaktionale Schritte	verwaiste Fragenzeile möglich	Codelage in askProactively; kein Vorfall beobachtet	WAHRSCHEINLICH

14. Technische Evidenz

Befund	Datei / Funktion	Datenquelle, Variable	DB-Objekt	Zeitstempel	Reproduzierbare r Test	Erwartet	Tatsächlich
Energie-Zeitanker	src/orb-core/engine.server.ts — getSnapshot(), recordLearning(), toState(); src/orb-core/core.ts — recoverEnergy, clamp01, ENERGY_RECOVERY_PERCENT_MIN, ENERGY_RECOVERY_CAPACITY	row.energy, row.updated_at	orb_state, Trigger orb_state_updated_at (BEFORE UPDATE, set_updated_at())	21.09. 06:30-11:34	tests/orb-energy-message-reset.test.ts (6 Tests, Fälle A-E)	Erholung überdauert einen Zwischen Schreibvorgang	vor der Behebung: Erholung verfiel, Anzeige 0
Energie-Gate	src/orb-core/curiosity.ts — decideCuriosity(), CURIOSITY_MIN_ENERGY = 0.15, CURIOSITY_ASK_THRESHOLD = 0.20	input.energy, score	orb_state.energy	21.09. 07:44 / 07:57	tests/orb-curiosity.test.ts (28 Tests)	WAIT unter 0.15	WAIT, Grund „Zu wenig Energie“
stay_silent unter 0.12	src/orb-core/core.ts — decide(); src/orb-core/conversation.ts — FOLLOW_UP, SMALLTALK	energy	orb_messages.decision	21.09. 07:44:26, 07:57:36	bestehende Konversationstests	Antwort ohne eigenen Beitrag	decision = stay_silent, Modus LISTEN
LISTEN ohne Wirkung auf Autonomie	src/orb-core/conversation.ts (ConversationMode, decideConversationMode, MODE_HINT); src/orb-core/llm/prompt.server.ts; src/orb-core/engine.server.ts — askProactively, formulateQuestion	mode	keine Spalte vorhanden	21.09.	Suche über src/ nach LISTEN, decideConversationMode, MODE_HINT	kein Gate	kein Gate; Modusfeld fehlt im Fragen-Prompt
Themenklassifikation	src/orb-core/memory.ts — topicOf(), TOPIC_KEYWORDS (Thema reisen enthält wander), Vergleich t.startsWith(k) k.startsWith(t)	Wortstamm wand	orb_nodes.topic	Entstehung 19.09. 19:24:02, Entdeckung 21.09.	Nachbau der Funktion mit dem Originalsatz	Thema aus Satzinhalt	Thema reisen
drei eigene Fragen	src/orb-core/engine.server.ts — askProactively(), loadCuriosityContext(), formulateQuestion(), isDuplicateQuestion	score, gap.kind, gap.topic, state_snapshot	orb_questions, orb_messages, orb_state, orb_metrics	21.09. 08:45:30 / 08:54:27 / 08:59:57	tests/orb-curiosity.test.ts, tests/orb-persistence.test.ts	vollständige Persistenz	vollständig, alle beantwortet
Long-Term-Memory	src/orb-core/recall.ts, src/orb-core/continuity.ts — certaintyOf() (0.6 / 0.3)	recalled, nodes_loaded	orb_nodes, orb_connections	19.09. 18:05:47 · 21.09. 08:59:13	tests/orb-memory.test.ts, tests/orb-memory-recall-fix.test.ts	Abruf persistierter Knoten	Abruf belegt, Stufe „wahrscheinlich“

Befund	Datei / Funktion	Datenquelle, Variable	DB-Objekt	Zeitstempel	Reproduzierbarer Test	Erwartet	Tatsächlich
Client-Gates	src/orb-core/presence.ts — shouldAskProactively(), PROACTIVE_MIN_IDLE_MS = 40_000, PROACTIVE_MAX_IDLE_MS = 900_000, PROACTIVE_COOLDOWN_MS; src/integrations/y-dude-orb/use-orb-presence.ts (Intervall 5 s, Sofortsperr)	idleMs, curiosity, pending	-	21.09.	tests/orb-presence.test.ts (20 Tests)	genau ein Aufruf je Freigabe	erfüllt
Nachdenken-Zustand	src/routes/_authenticated/channels.orb.tsx (pending-Quelle, Abbruch bei !asked), src/components/orb/OrbChat.tsx (Hinweistext), src/orb-core/llm/openai.server.ts (AbortSignal.timeout)	isPending, result.asked	-	21.09. 11:30	Abgleich aller Erfolgs- und Fehlerzweige	Hinweis endet immer	endet immer; kein sichtbarer Abschluss bei Ablehnung
Beobachtbarkeit	src/components/orb/OrbDevPanel.tsx, src/routes/_authenticated/channels.orb.tsx (lastAutonomyAttempt)	asked, action, reason, topic, kind, score	-	21.09.	Sichtprüfung im Testbereich	letzter Versuch sichtbar	sichtbar, nur sitzungslokal

15. Was heute NICHT bewiesen wurde

1. Welches Gate den Versuch um 11:30 UTC ablehnte — Ablehnungen werden nicht persistiert. **OFFEN**
 2. Ob im beobachteten Ereignis überhaupt ein Serveraufruf erfolgte oder bereits ein clientseitiges Gate griff. **OFFEN**
 3. Der exakte Minutenverlauf der Energieanzeige — es wird kein Energieverlauf gespeichert; Zwischenwerte wurden ausdrücklich nicht rekonstruiert. **OFFEN**
 4. Ob der Abruf um 18:05:47 (19.09.) die **einzigste** Quelle der genannten Fakten war; das Kontextfenster hätte den Rohsatz ebenfalls enthalten. **WAHRSCHEINLICH**
 5. Ob die beobachtete Selbstkorrektur wiederholbar ist; sie ist Modellverhalten ohne Prüfmechanismus. **OFFEN**
 6. Ob Teilpersistenz im eigenständigen Fragenweg praktisch aufgetreten ist; nur die Codelage erlaubt sie. **WAHRSCHEINLICH**
 7. Die exakte Commit-Kennung des veröffentlichten Production-Bündels — aus dem minimierten Bündel nicht ableitbar; belegt ist nur, dass die erwarteten Textbausteine enthalten sind. **OFFEN**
 8. Ob mehrere gleichzeitig geöffnete Ansichten in der Praxis zum Zeitanker-Verlust beitrugen; sie würden ihn nur häufiger auslösen, die Obergrenze bleibt eingehalten. **WAHRSCHEINLICH**
 9. Wie häufig eine falsche Themenzuordnung insgesamt auftritt; belegt ist ein Einzelfall und der Mechanismus, keine Häufigkeit. **OFFEN**
 10. Auswirkungen der Energie-Schwellen 0.12 und 0.20 auf Anschlussfragen, Smalltalk und Avatar-Darstellung im realen Mobilbetrieb. **OFFEN**
-

16. Abschlussbewertung

KAUSAL BESTÄTIGT

1. Verlust des Erholungs-Zeitankers durch orb_state-Schreibvorgänge ohne energy in Verbindung mit dem Zeitstempel-Trigger; Wirkung bis zur angezeigten Energie 0.
2. Anzeige-/Persistenz-Fehlpassung als Ursache des Abfalls von 11-15 % auf ≈ 1 %.
3. Energie unter 0.15 als Ursache ausbleibender eigener Fragen (WAIT).
4. Energie unter 0.12 als Ursache von stay_silent und damit der LISTEN-Formulierung.
5. LISTEN ist kein ausführbares Hindernis für den eigenständigen Fragenweg (widerlegt).
6. Korrekte, zeitbasierte Energie-Erholung mit live belegten Werten bis zur Obergrenze 0.25.
7. Falsche Themenzuordnung reisen durch bidirektionalen Wortstammvergleich, entstanden am 19.09.
8. Drei eigene Fragen am 21.09., alle über den CURIOSITY-Zweig, vollständig persistiert.
9. Long-Term-Memory-Retrieval persistierter Knoten mit berechneter Sicherheitsstufe.
10. Vollständige Kette Eingabe → Persistenz → Zustandsänderung → Abruf → Folgeverhalten (19.09.).
11. 24 von 25 Ablehnungspunkten ohne jede dauerhafte Spur.
12. Der Nachdenken-Hinweis kann nicht hängen bleiben; das beobachtete Muster entsteht durch den bewussten Abbruch bei asked = false.

DIREKT BEOBACHTET

1. „ORB denkt ...“ ohne sichtbare Folge während des Live-Tests am 21.09. gegen 11:30 UTC.
2. Selbstkorrektur der Reise-Annahme im Antworttext.
3. Sichtbares Absinken der Energieanzeige ohne erkennbare Nutzeraktion.
4. Der zuvor im Testbereich beobachtete abgelehnte Versuch mit Wert 0.643.

OFFEN

1. Konkretes ablehnendes Gate des Ereignisses um 11:30 UTC.
2. Minutenverlauf der Energieanzeige.
3. Exklusivität des Abrufs als Faktenquelle am 19.09. um 18:05:47.
4. Wiederholbarkeit der Selbstkorrektur.
5. Häufigkeit falscher Themenzuordnungen.
6. Praktische Auswirkungen der Schwellen 0.12 und 0.20 im Mobilbetrieb.
7. Commit-Kennung des veröffentlichten Bündels.
8. Tatsächliches Auftreten von Teilpersistenz im eigenständigen Fragenweg.

Source reports analyzed: 15 Causally confirmed findings: 12 Observed-only findings: 4 Probable findings: 4 Open findings: 8 Files changed in application: 0 Database changes: 0 Migrations: 0 Deployments: 0 Configuration changes: 0 Tests changed: 0