

# Y-Dude — Production Load Test bis 750 virtuelle Nutzer

Messbericht · Production <https://y-dude.com> · 30.08.2026, 04:20-05:05 UTC · read-only, ausschließlich anonyme synthetische Sessions

## 1. Executive Summary

Die veröffentlichte Production-Version wurde in fünf Stufen (50 / 100 / 250 / 500 / 750 virtuelle Nutzer) mit realistischen Lesepfaden belastet. Alle fünf Stufen wurden erreicht und blieben stabil. Über 94.720 Requests traten 0 Serverfehler (5xx), 0 4xx-Fehler und 1 Timeout auf. Die Antwortzeiten blieben über alle Stufen nahezu konstant (p95 45-66 ms); bei 750 Nutzern lag der Durchsatz bei 366 Requests/s mit p50 32 ms, p95 45 ms, p99 114 ms.

750 virtuelle Nutzer erfolgreich getestet. Ein Bottleneck wurde im getesteten Lastbereich nicht erreicht — weder Backend, Datenbank, Auth, Storage noch CDN zeigten Sättigungsanzeichen. Der SSR-Kurzzeitcache für öffentliche Beitragsseiten arbeitete unter Last mit steigender Trefferquote (79 % bei 50 VUs → 92 % bei 750 VUs) und war damit der wirksamste Skalierungshebel der Messung. Einschränkung der Messung: Angemeldete Pfade (Feed-Daten, View-Batch, Translation-Batch, Messenger, Market-Daten) konnten nicht belastet werden, weil keine dedizierten Testkonten in Production existieren und laut Auftrag keine Testdaten angelegt werden durften. Serverseitige Kennzahlen (CPU, RAM, DB-Connections) sind nicht messbar: der interne Messendpunkt antwortet in Production mit HTTP 500, der DB-Health-Abruf mit „metrics payload exceeded size cap“. Diese beiden Punkte wurden auftragsgemäß NICHT behoben.

## 2. Testziel

Ermitteln, wie sich die aktuell veröffentlichte Production-Version unter steigender gleichzeitiger synthetischer Nutzerlast verhält, wo Latenz und Fehlerquote messbar ansteigen und wo die tatsächlichen Skalierungsgrenzen liegen. Reiner Mess- und Analyseauftrag: keine Optimierung, keine Code-, DB-, RLS-, Index-, CDN-, Storage- oder Secret-Änderung.

## 3. Production-Ausgangszustand (gemessen vor der Last)

| Prüfpunkt                                                    | Ergebnis                                                                                                                                           |
|--------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------|
| Kanonischer Host                                             | y-dude.com (y-dude.lovable.app und www.y-dude.com → 302 auf y-dude.com)                                                                            |
| Erreichbarkeit /, /auth, /agb, /market, /globe, /richtlinien | alle HTTP 200                                                                                                                                      |
| Öffentliche Beitragsseite /post/<uuid>                       | HTTP 200, Header vary: Cookie, Authorization, x-ydude-cache vorhanden                                                                              |
| cache-control auf HTML                                       | no-cache, must-revalidate, max-age=0 (der s-maxage-Wert des Performance-Release greift nicht, da bereits eine cache-control-Kopfzeile gesetzt ist) |
| Auth-Endpunkt (GoTrue health)                                | HTTP 200, 90 ms                                                                                                                                    |
| Anonymer Lesezugriff posts                                   | HTTP 401 permission denied (erwartet)                                                                                                              |
| Anonymer Lesezugriff comments                                | HTTP 200 (bekannte, zuvor als Rating C dokumentierte Altlast)                                                                                      |
| Interner Metrik-Endpunkt /api/public/cache-metrics           | HTTP 500 nach erfolgreicher Autorisierung → Serverkennzahlen nicht messbar                                                                         |
| DB-Health-Snapshot                                           | Fehler „metrics payload exceeded size cap“ → DB-CPU/Connections nicht messbar                                                                      |

Feststellung (Messung, keine Änderung): /feed und /dashboard existieren in Production nicht (404); der Feed-Einstieg läuft über /arena (307 auf das Login-Gate für Anonyme).

## 4. Testmethodik

Eigener Lastgenerator (Bun/TypeScript, Sandbox in Frankreich, CF-Edge CDG). Jeder virtuelle Nutzer durchläuft in Endlosschleife eine realistische Sitzung mit Wartezeiten von 0,5–4 s zwischen den Aktionen:

1. Landing / — 2. Bundle-Asset (CDN) — 3. Login-Seite /auth — 4. Auth-API (GoTrue health) — 5. Feed-Einstieg /arena — 6. Marketplace /market — 7. Globe /globe — 8. zwei bis drei öffentliche Beiträge /post/<uuid> (12 reale, öffentliche Beiträge, zufällig gewählt) — 9. Kommentare des jeweiligen Beitrags (Datenpfad mit RLS) — 10. eine Rechtsseite (AGB/Datenschutz/Impressum/Richtlinien).  
Ramp-up 10 s je Stufe, Messdauer 90 s (Stufe 750: 120 s), zwischen den Stufen Stabilisierungspause. Timeout 15 s. Automatischer Abbruch, sobald über 10 % der letzten 300 Requests mit 5xx oder Timeout enden. Keine Schreibvorgänge, keine Logins, keine Zahlungen, keine E-Mails, keine Testdaten, keine echten Nutzerkonten. Redirects wurden nicht gefolgt (307 des Login-Gates wird als Erfolg gezählt).

## 5.-9. Laststufen und Messwerte

| VUs | Dauer | Requests | Req/s | Erfolg | Fehler | 5xx | 4xx | Timeouts | p50   | p95   | p99    | max      |
|-----|-------|----------|-------|--------|--------|-----|-----|----------|-------|-------|--------|----------|
| 50  | 103 s | 2490     | 24    | 2490   | 0      | 0   | 0   | 0        | 33 ms | 66 ms | 150 ms | 470 ms   |
| 100 | 104 s | 4948     | 48    | 4948   | 0      | 0   | 0   | 0        | 35 ms | 51 ms | 134 ms | 761 ms   |
| 250 | 105 s | 12432    | 118   | 12432  | 0      | 0   | 0   | 0        | 34 ms | 53 ms | 139 ms | 690 ms   |
| 500 | 106 s | 24898    | 235   | 24898  | 0      | 0   | 0   | 0        | 32 ms | 45 ms | 118 ms | 1109 ms  |
| 750 | 136 s | 49952    | 366   | 49951  | 1      | 0   | 0   | 1        | 32 ms | 45 ms | 114 ms | 15001 ms |

## Latenz je Nutzeraktion (p95 / p99 in ms)

| Aktion              | 50 VUs    | 100 VUs   | 250 VUs   | 500 VUs   | 750 VUs   |
|---------------------|-----------|-----------|-----------|-----------|-----------|
| Login-Seite         | 42 / 69   | 44 / 246  | 46 / 66   | 40 / 53   | 40 / 62   |
| Auth-API            | 48 / 81   | 47 / 73   | 44 / 66   | 43 / 54   | 43 / 75   |
| Feed-Einstieg       | 36 / 38   | 41 / 64   | 41 / 72   | 35 / 53   | 36 / 49   |
| öffentl. Post (SSR) | 151 / 196 | 125 / 159 | 131 / 258 | 115 / 144 | 109 / 139 |
| Kommentare (RLS)    | 49 / 77   | 48 / 58   | 47 / 77   | 48 / 104  | 47 / 80   |
| Marketplace         | 45 / 56   | 48 / 160  | 51 / 81   | 46 / 71   | 46 / 69   |
| Globe               | 44 / 53   | 48 / 254  | 50 / 77   | 46 / 69   | 44 / 60   |
| Asset (CDN)         | 32 / 61   | 37 / 62   | 37 / 112  | 32 / 39   | 32 / 45   |
| Landing             | 39 / 117  | 44 / 96   | 50 / 257  | 41 / 60   | 42 / 90   |
| Rechtsseiten        | 42 / 56   | 50 / 69   | 45 / 68   | 41 / 52   | 41 / 52   |

Alle Stufen: 5xx = 0, 4xx = 0. Der einzige Timeout der gesamten Messung trat in Stufe 750 auf (1 von 49.952 Requests = 0,002 %) und erklärt dort den Maximalwert von 15.001 ms (Abbruch durch das Client-Timeout).

## 10. Datenbank- und Backend-Auslastung

| Kennzahl                                           | Ergebnis                                                                                                                  |
|----------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| DB CPU                                             | nicht messbar (DB-Health-Abwurf schlägt mit „metrics payload exceeded size cap“ fehl)                                     |
| DB Connections / Connection Pool                   | nicht messbar (gleiche Ursache)                                                                                           |
| Query-Latenzen / RLS-Query-Latenzen (serverseitig) | nicht messbar; indirekt über Endpunktlatenz: Kommentare (RLS-Pfad) p95 49 ms bei 50 VUs, 46 ms bei 750 VUs — kein Anstieg |
| Server CPU / RAM / Event-Loop-Lag                  | nicht messbar (interner Metrik-Endpoint antwortet mit HTTP 500)                                                           |
| Storage Requests                                   | nicht messbar; im Testpfad wurden keine Medien-Originale abgerufen (nur HTML + ein Bundle-Asset)                          |
| Netzwerk/Bandbreite                                | nicht direkt messbar; Lastgenerator-Durchsatz max. ca. 366 Requests/s, überwiegend HTML/JSON                              |
| View-Batch-Requests                                | nicht messbar — nur im angemeldeten Feed aktiv, mangels Testkonto nicht belastet                                          |
| Translation-Batch-Requests                         | nicht messbar — gleiche Ursache                                                                                           |

## 11. Cache-Verhalten (gemessen)

| VUs | Post-Seiten | SSR HIT | SSR MISS | HIT-Quote | p50 HTML | p95 Post | p99 Post |
|-----|-------------|---------|----------|-----------|----------|----------|----------|
| 50  | 437         | 345     | 92       | 79 %      | 33 ms    | 151 ms   | 196 ms   |
| 100 | 858         | 748     | 110      | 87 %      | 35 ms    | 125 ms   | 159 ms   |
| 250 | 2172        | 1881    | 291      | 87 %      | 34 ms    | 131 ms   | 258 ms   |
| 500 | 4361        | 3937    | 424      | 90 %      | 32 ms    | 115 ms   | 144 ms   |
| 750 | 9083        | 8340    | 743      | 92 %      | 32 ms    | 109 ms   | 139 ms   |

Auch Landing (192/202 HIT bei 50 VUs), Login-Seite (197/202) und Rechtsseiten (183/202) wurden aus dem SSR-Kurzzeitcache bedient. Die HIT-Quote steigt mit der Last, weil mehr Anfragen innerhalb der TTL auf dieselbe Worker-Instanz treffen. Bei Einzelaufrufen (Leerlauf, sequenziell) wurde dagegen mehrfach „miss“ gemessen: der Cache ist instanzlokal, nicht geteilt. Zusätzlich trägt das HTML weiterhin cache-control: no-cache — der im Performance-Release vorgesehene s-maxage/CDN-Anteil wird dadurch in Production nicht wirksam (Messung, keine Änderung).

## 12. View-/Translation-Batch-Verhalten

Nicht messbar. Beide Mechanismen greifen ausschließlich im angemeldeten Feed. Für Production existieren keine dedizierten Testkonten, und das Anlegen von Testdaten war ausdrücklich untersagt. Die Launchpad-Referenzwerte (View 6 → 1 Request, Translation 3-4 → 1 Request, 26-27 → 18-19 Backend-Requests bei 6 Posts) konnten daher nicht gegen Production verifiziert werden. Vergleichbar ist nur der SSR-HIT: Referenz ca. 4-5 ms lokal, in Production liefert eine gecachte Beitragsseite Ende-zu-Ende p50 ≈ 31 ms inklusive Internet-Roundtrip zum Edge.

## 13. Sicherheitsprüfung unter/nach Last

| Prüfung                                              | Ergebnis                                                                                                                                             |
|------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|
| SSR-Cache: öffentliche Posts HIT/MISS korrekt        | OK — nur wirklich öffentliche Beiträge werden gecacht; eine unbekannte/nicht öffentliche UUID erzeugt keinen Cache-Eintrag und keine Cache-Kopfzeile |
| Cookie/Authorization → kein gemeinsamer Cache        | OK — Anfragen mit Cookie oder Authorization erhalten weder x-ydude-cache noch den internen Marker; vary: Cookie, Authorization ist gesetzt           |
| Interner Marker x-ydude-public-post nie ausgeliefert | OK — auf allen geprüften Pfaden entfernt                                                                                                             |
| RLS unter Last                                       | OK — anonym: posts 401 permission denied, profiles 401, messages leere Menge; keine Umgehung beobachtet                                              |

| Prüfung                   | Ergebnis                                                                                                                                 |
|---------------------------|------------------------------------------------------------------------------------------------------------------------------------------|
| Session-Isolation         | OK — keine Cross-User-Daten; der Lasttest lief vollständig ohne Sitzung, ausgelieferte Seiten waren identisch und unpersonalisiert       |
| React Query Focus-Refetch | nicht messbar auf HTTP-Ebene (Browser-Verhalten); Code-Default refetchOnWindowFocus: false unverändert aktiv                             |
| Beobachtung (unverändert) | comments ist anonym lesbar (HTTP 200, Inhalte). Entspricht dem bereits dokumentierten Audit-Rating C, wurde auftragsgemäß nicht geändert |

## 14. Erster erkennbarer Bottleneck

Im getesteten Bereich bis 750 virtuelle Nutzer wurde kein Bottleneck erreicht. Latenz und Fehlerquote steigen nicht mit der Last — p95 sinkt von 66 ms (50 VUs) auf 45 ms (750 VUs), weil die Cache-Trefferquote steigt. Der erste erkennbare Engpass ist damit nicht serverseitig, sondern messtechnisch: die fehlende Beobachtbarkeit (Metrik-Endpunkt 500, DB-Health nicht abrufbar) verhindert die Bestimmung der Sättigungsgrenze.

## 15. Skalierungsbewertung (nur aus Messwerten)

| Frage                             | Antwort aus der Messung                                                                                                     |
|-----------------------------------|-----------------------------------------------------------------------------------------------------------------------------|
| Bis zu welcher Nutzerzahl stabil? | mindestens 750 gleichzeitige virtuelle Leser, 366 Req/s, 0 5xx                                                              |
| Wo steigt Latenz messbar?         | nirgends im getesteten Bereich (p95 45–66 ms, ohne Trend nach oben)                                                         |
| Wo steigt die Fehlerquote?        | nirgends; 1 Timeout bei 750 VUs = 0,002 %                                                                                   |
| Erster Bottleneck                 | im Messbereich nicht erreicht                                                                                               |
| Datenbank Bottleneck?             | nein, soweit sichtbar — RLS-Lese Pfad (Kommentare) bleibt konstant bei p95 ≈ 46–49 ms. Direkte DB-Kennzahlen: nicht messbar |
| Auth Bottleneck?                  | nein — Auth-API p95 48 ms (50 VUs) → 40 ms (750 VUs). Login-/Token-Ausgabe wurde nicht belastet (keine Testkonten)          |
| Backend/Server Bottleneck?        | nein — SSR-Antworten bleiben unter Last konstant                                                                            |
| Storage Bottleneck?               | nicht beurteilbar — im Testpfad nicht belastet                                                                              |
| Netzwerk/CDN Bottleneck?          | nein — Bundle-Asset p95 32 ms → 27 ms; Grenze lag eher beim Lastgenerator als am Edge                                       |
| Nutzen der Caches/Batches         | hoch für SSR (79 % → 92 % HIT). View-/Translation-Batch: nicht messbar                                                      |

## 16./17. Empfehlungen und Prioritätenplan

Interpretation und Empfehlung — nicht Messung. Auftragsgemäß nicht umgesetzt.

| Prio   | Maßnahme                                                | Problem / Nachweis                                                                                                                                                      | Nutzen                                         | Risiko                                        | Aufw. | vor Wachstum? |
|--------|---------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------|-----------------------------------------------|-------|---------------|
| HOCH   | Serverkennzahlen wieder verfügbar machen                | /api/public/cache-metrics antwortet nach gültiger Autorisierung mit HTTP 500; DB-Health nicht abrufbar → CPU, RAM, Connections, Event-Loop-Lag, Batch-Zähler sind blind | Sättigungsgrenze wird überhaupt bestimmbar     | gering (nur Messpfad)                         | klein | ja            |
| MITTEL | Dedizierte Produktion-Testkonten (nur lesend, isoliert) | Angemeldete Pfade inkl. View-/Translation-Batch, Messenger, Market-Daten sind ungetestet                                                                                | Lasttest deckt die tatsächlich teuren Pfade ab | mittel (Prod-Daten) → strikt getrenntes Konto | klein | ja            |

| Prio    | Maßnahme                                                              | Problem / Nachweis                                                                                                                                                                    | Nutzen                                                                                                             | Risiko                                                                                                            | Aufw.  | vor Wachs-<br>tum?   |
|---------|-----------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|--------|----------------------|
| MITTEL  | CDN-Caching für öffentliche HTML-Seiten aktivieren (separat bewertet) | HTML trägt cache-control: no-cache; der s-maxage-Zweig greift nicht, weil bereits eine cache-control-Kopfzeile gesetzt ist. SSR-Cache ist instanzlokal (sequenzielle Aufrufe: „miss“) | öffentliche Seiten würden am Edge statt in der Instanz bedient; entlastet Worker und DB deutlich stärker als heute | mittel — Fehlkonfiguration könnte personalisierte Inhalte cachen; vary: Cookie, Authorization ist bereits gesetzt | mittel | empfohlen vor 5.000+ |
| NIEDRIG | Lastprofil mit Medien/Storage erweitern                               | Storage im Test nicht belastet, obwohl Feed-Medien der größte Bandbreitenposten sind                                                                                                  | realistische Bandbreiten- und Storage-Grenzen                                                                      | gering                                                                                                            | klein  | nein                 |
| NIEDRIG | Lasttest von mehreren Regionen                                        | Messung nur aus einer Edge-Region (CDG)                                                                                                                                               | Erkennt regionale Latenz- und Cache-Effekte                                                                        | gering                                                                                                            | klein  | nein                 |
| KEINE   | Compute-Instanz vergrößern                                            | Kein Sättigungsnachweis bei 750 VUs                                                                                                                                                   | aktuell kein messbarer Nutzen                                                                                      | –                                                                                                                 | –      | nein                 |
| KEINE   | Index-/Query-Optimierung                                              | Keine Latenzsteigerung im Lese-pfad messbar                                                                                                                                           | aktuell kein messbarer Nutzen                                                                                      | –                                                                                                                 | –      | nein                 |

Ausbaustufen — ausschließlich als Ableitung aus dem Gemessenen, ohne Kapazitätsversprechen: 1.000 Nutzer: keine Maßnahme aus der Messung ableitbar; zuerst Beobachtbarkeit herstellen (Prio HOCH). 5.000 Nutzer: nicht gemessen; erforderlich sind Edge-Caching öffentlicher Seiten und ein Lasttest der angemeldeten Pfade, da genau diese ungemessen sind. 10.000 Nutzer: nicht gemessen; ohne DB-/Connection-Kennzahlen ist keine belastbare Aussage möglich — Voraussetzung ist eine Messung mit angemeldeter Schreib-/Leselast. 100.000 Nutzer: aus dieser Messung nicht ableitbar; grundsätzlich betrifft das Architekturebenen (Read-Replicas, dedizierte Medien-/CDN-Strategie, Warteschlangen für Schreibpfade), die hier bewusst nicht quantifiziert werden.

## 18. Abbruchgrund

Entfällt — kein Abbruch. Kein Abbruchkriterium wurde ausgelöst (keine 5xx-Häufung, keine Timeout-Welle, keine Auth-Instabilität, keine Rate-Limit-/Abuse-Auslösung, kein Rückstau).

## 19. Fazit

Die Production-Version von Y-Dude verhält sich bis 750 gleichzeitigen anonymen Lesernutzern (366 Requests/s, 49.952 Requests in 120 s) fehlerfrei und mit konstanter Latenz. Der SSR-Kurzzeitcache ist der wirksame Skalierungsfaktor und arbeitet sicherheitskonform (keine Vermischung personalisierter Anfragen). Nicht abgedeckt bleiben angemeldete Pfade und serverseitige Kennzahlen; beides ist Voraussetzung, um eine echte Obergrenze zu bestimmen. Am Production-System wurde nichts verändert.

## 20. Getestete Maximalstufe

750 virtuelle Nutzer erfolgreich getestet — Stufe 5 vollständig durchlaufen, 0 Serverfehler, 1 Timeout (0,002 %), p95 45 ms.

Rohdaten (maschinenlesbar): docs/Y-DUDE\_PRODUCTION\_LOADTEST\_750\_USERS\_2026-08-30.json — enthält je Stufe alle Zähler, Statuscodes und Perzentile pro Nutzeraktion.